

UNIVERSITÀ DEGLI STUDI DI MILANO–BICOCCA
SCUOLA DI ECONOMIA E STATISTICA

CORSO DI LAUREA IN
SCIENZE STATISTICHE ED ECONOMICHE



**NEGATIVE BINOMIAL REGRESSION
COME SOLUZIONE A CASI DI
SOVRADISPERSIONE IN DATI DI
CONTEGGIO**

RELATORE: Dott. Roberto Ascari

TESI DI LAUREA DI:
Giuditta Adezio
MATRICOLA N. 880076

ANNO ACCADEMICO 2023/2024

Indice

1	INTRODUZIONE	1
1.1	LA STORIA	1
1.2	ACCENNO GENERALE ALLA NEGATIVE BINOMIAL	3
2	FONDAMENTI TEORICI	5
2.1	MODELLI CON RISPOSTA CONTEGGIO	5
2.1.1	STIMA DEL MODELLO	6
2.2	POISSON	7
2.2.1	RELAZIONE TRA POISSON E BINOMIALE	10
2.2.2	POISSON COME ELEMENTO DELLA FAMIGLIA ESPO- NENZIALE	11
2.2.3	POISSON RATE MODEL	12
2.3	SOVRADISPERSIONE	13
2.3.1	QUASI-VEROSIMIGLIANZA POISSON	14
2.4	NEGATIVE BINOMIAL	16
2.4.1	NEGATIVE BINOMIAL COME GLM	19
2.4.2	NEGATIVE BINOMIAL LINEARE O NB ₁	22
2.4.3	ALTRE FORME DI NEGATIVE BINOMIAL	24
3	APPLICAZIONE	27
3.1	ANALISI DESCRITTIVE	29
3.2	STIMA DEI MODELLI	31
3.2.1	STIMA DEL MODELLO POISSON	31
3.2.2	STIMA DEL MODELLO NEGATIVE BINOMIAL	33
3.2.3	STIMA DI ULTERIORI MODELLI PER LA GESTIONE DELLA SOVRADISPERSIONE POISSON	35
3.3	CONFRONTO MODELLI	36
4	CONCLUSIONE	39

A CODICE R	41
Bibliografia	57

*A mio fratello Marco,
a Luca e Agnese.*

Capitolo 1

INTRODUZIONE

La Negative Binomial regression è un metodo di regressione principalmente utilizzato per dati di conteggio in caso di sovradisersione.

Esistono molteplici ragioni per cui i dati di conteggio possono risultare sovradispersi, come ad esempio un numero eccessivo di zeri o la correlazione tra le osservazioni. Per affrontare questo problema, è stata sviluppata una vasta gamma di metodi risolutivi. Tuttavia, quando la causa della sovradisersione è ignota, il metodo migliore è la Negative Binomial regression. Si tratta di un metodo statistico non molto comune e che presenta innumerevoli parametrizzazioni, le une diverse dalle altre.

1.1 LA STORIA

Come scritto da Isaac Todhunter nel suo *History of the Mathematical Theory of Probability from the Time of Pascal to that of Laplace* [Todhunter \(1865\)](#), il primo a menzionare il modello Negative Binomial fu, nel 1713, uno dei matematici più importanti dei suoi giorni, Pier De Montmort, riferendosi a esso come il numero di fallimenti prima dell' r -esimo successo in una serie di prove binarie. Si dice abbia fatto riferimento a tale distribuzione per la prima volta nel suo *Essay on the Analysis of Games of Chance* [Montmort \(1708\)](#), ma che l'abbia sviluppata solo cinque anni dopo.

La distribuzione Poisson, invece, nasce dal lavoro dell'omonimo Simeon Poisson. Questa, derivata innanzitutto come metodo per capire la distribuzione di dati di conteggio, divenne nel tempo il metodo standard per i modelli di conteggio. (In seguito vedremo come le due distribuzioni appena citate siano strettamente collegate).

In generale con la prima definizione di Negative Binomial, però, fu fatto molto

poco fino al ventesimo secolo. Dopo l'introduzione della distribuzione Normale o curva Gaussiana, ad opera di Gauss, sulla quale si basa la regressione ai minimi quadrati o OLS (ordinary least squares), la Negative Binomial è stata ancora una volta derivata da William Gosset nel 1907 sotto pseudonimo di Student. L'articolo sulla Negative Binomial, scritto da Gosset nel Laboratorio Biometrico di Karl Pearson a Londra, è stato pubblicato in *Biometrika* (rivista britannica creata nel 1901 da Karl Pearson).

Generalmente però si attribuisce la prima vera definizione di distribuzione Negative Binomial a G.Udny Yule nel 1910 in un articolo che trattava del numero di decessi in relazione al numero di esposizioni a una determinata malattia. Lo stesso Yule, insieme a Greenwood, dieci anni dopo, definì quella che noi attualmente chiamiamo NB-C (Negative Binomial canonica), rendendo ancora più sofisticato il lavoro di Montmort. Nel 1923 si giunse invece alla definizione della Negative Binomial come noi la intendiamo adesso, basata cioè su una mistura, grazie a Eggenberger e Polya. I due svilupparono la Negative Binomial trattando il parametro λ della Poisson come una variabile casuale con distribuzione Gamma. In seguito, il lavoro di Anscombe portò alla definizione del primo modello di regressione Negative Binomial, ma come regressione non lineare con solo l'intercetta. Più tardi lo stesso Anscombe definì anche la Negative Binomial regression come serie di distribuzioni logaritmiche e discusse anche parametrizzazioni alternative della stessa. Per finire, nel 1953 Evans derivò quella a cui oggi noi ci riferiamo come NB1 o Negative Binomial lineare.

Il primo, invece, a sviluppare un metodo di massima verosimiglianza che si adattasse alla Negative Binomial fu, negli anni 60, l'attuario Leroy Simon. Bisognò attendere, però, il 1981 per ottenere, grazie a Plackett, una stima di massima verosimiglianza con un singolo predittore per la Negative Binomial.

Per analisi statistiche più accurate, si è dovuto aspettare l'avvento dei personal computer. Infatti, prima di tale evento, le statistiche più complesse venivano effettuate attraverso dei computer mainframe e le analisi interattive non venivano del tutto effettuate; l'utilizzo di tali computer necessitava di molto tempo e denaro. In seguito allo sviluppo dei Modelli Lineari Generalizzati (GLM), si è verificato un cambio di tendenza nell'approccio alle regressioni non lineari; con un passaggio dall'analisi dettagliata delle relazioni tra le varie distribuzioni e le loro specifiche caratteristiche, verso la costruzione di modelli non lineari che includessero variabili esplicative.

Ad oggi software come R, Stata e SAS includono funzioni specifiche per modellizzare la Negative Binomial.

1.2 ACCENNO GENERALE ALLA NEGATIVE BINOMIAL

Solitamente ci si riferisce alla Negative Binomial come se fosse un unico modello, come ad esempio la regressione logistica. Tuttavia non è così: esistono diversi tipi di Negative Binomial; attualmente, le forme ufficiali riconosciute sono venticinque, e questa distribuzione può essere derivata in numerosi modi. Boswell e Patil [Boswell \(1970\)](#) ne hanno identificati 13 ma molti statistici sostengono che ce ne siano di più.

Il modello di una Negative Binomial standard, quello predominante a fini statistici e interpretativi, è chiamato NB2 ([Cameron & Trivedi \(1986\)](#)) o Negative Binomial quadratica. Questo perché, come già accennato in precedenza, naturalmente esiste anche una NB1 (Negative Binomial lineare); la differenza tra le due sta nei secondi termini della varianza che, come suggeriscono i due nomi, risultano uno il quadrato dell'altro. Sia la NB1 che la NB2 utilizzano un algoritmo di massima verosimiglianza per la stima dei parametri, ma nel caso della NB2 solitamente si utilizza un algoritmo IRLS con lo scopo di far rientrare la distribuzione in questione nei GLM.

La distribuzione della Negative Binomial standard, secondo una parametrizzazione abbastanza recente, si basa su una funzione di probabilità (FDP) derivata da una mistura Poisson-Gamma e permette di modellizzare l'eterogeneità (o sovradisersione) della prima. In un modello Poisson, che si potrebbe definire un modello Negative Binomial con parametro di eterogeneità pari a zero, la media è uguale alla varianza; pertanto all'aumentare del valore della media aumenta la variabilità (si ipotizza equidispersione). Questo modello assume inoltre che gli eventi soggetti al processo di conteggio siano tra di loro indipendenti. La violazione delle suddette ipotesi solitamente risulta in una situazione di extradispersione (sovradisersione o sottodispersione), anche perché è molto raro che nei dati reali si verifichi effettivamente un caso di equidispersione. Nello specifico, se la varianza campionaria risulta essere di molto superiore alla media, allora si parla di sovradisersione, nel caso contrario di sottodispersione. Quest'ultima si verifica molto di rado, dunque ci troviamo più spesso di fronte a un caso di sovradisersione e pertanto, solitamente, ci si focalizza su questa. La NB2 ha di base le stesse assunzioni di una Poisson, ad eccezione del secondo parametro

(parametro di dispersione) che permette alla distribuzione di dati di conteggio di avere una forma più ampia rispetto a quanto si poteva assumere con un modello Poisson. Infatti, la varianza di una Negative Binomial standard dipende da due parametri μ^2 e α ; pertanto all'aumentare della media (μ) aumenterà il quadrato della stessa e quindi la varianza.

Tuttavia, la prima definizione di una Negative Binomial non si basa su una mistura Poisson-Gamma ma sulla FDP di una Binomiale (da cui appunto prende il nome); in particolare viene definita come il numero di tentativi falliti prima dell' r -esimo successo in una serie di prove Bernoulliane indipendenti. Questa parametrizzazione appena descritta la indichiamo come NB-C.

Le forme di Negative Binomial sopra specificate sono chiaramente le più utilizzate e, in seguito, dimostreremo che, dal momento che al divergere di n una distribuzione Binomiale tende a una di Poisson, sono anche strettamente correlate. La fondamentale differenza è che, con la NB2, siamo in grado di modellizzare la sovradisersione per dati di conteggio, cosa che non potremmo fare con la NB-C, nonostante trasformando quest'ultima si possa ricavare facilmente la NB2. Inoltre la NB2 risulta di più facile interpretazione e, essendo anche parte dei Generalized Linear Models (GLM) con parametro di eterogeneità inserito come costante, comporta anche molti vantaggi dal punto di vista statistico.

Esiste anche una forma generalizzata, di solito indicata come NBP (il cui nome deriva sempre dall'esponente del secondo parametro della varianza). Da quest'ultima possiamo ricavare, come casi particolari, la NB1 e la NB2. Parametrizzando α (parametro di dispersione) si ottiene, invece, una Negative Binomial Eterogenea (NB-H). Nel caso in cui, invece, α sia pari a uno otterremmo una distribuzione geometrica.

Come possiamo ben vedere esistono molte tipologie di Negative Binomial ed è molto importante conoscere qual è quella sottostante al modello stimato per valutare e interpretare al meglio i risultati ottenuti.

Questa tesi propone un'analisi approfondita dei modelli di conteggio in generale, con un particolare focus sulla distribuzione di Poisson e sulla sovradisersione, fenomeno comune nei dati di conteggio. Successivamente, si intende finalmente esaminare la Negative Binomial regression come soluzione alla sovradisersione, concentrandosi sulle varianti più utilizzate, quali la NB1, la NB2 e la NB-C. L'obiettivo ultimo è analizzare come questa distribuzione si adatti ai dati reali, anche in confronto ad altri modelli.

Capitolo 2

FONDAMENTI TEORICI

2.1 MODELLI CON RISPOSTA CONTEGGIO

I modelli a risposta conteggio sono un sottoinsieme dei modelli di regressione con risposta discreta (come ad esempio la binary logistic e la probit regression). Una variabile risposta è un conteggio se assume un valore discreto di conteggio, come ad esempio il numero di frequentanti del terzo anno di SSE all'università degli studi Milano Bicocca. In statistica, solitamente, con dati di conteggio ci si riferisce a osservazioni che hanno solo valori interi non negativi, che appartengono ad un range che va da zero a infinito, anche se solitamente sono limitati a qualche valore distinto inferiore (generalmente il massimo valore assunto dai dati di conteggio che stiamo modellizzando).

Tutti i modelli per dati di conteggio hanno come obiettivo quello di rappresentare il numero di occorrenze di un determinato evento. Gli stessi conteggi sono intrinsecamente eteroschedastici, asimmetrici positivi e la loro varianza aumenta all'aumentare della media della distribuzione.

Tutti i modelli di conteggio sono parametrizzati in termini di rate ratios, calcolati attraverso un'esponenziale dei coefficienti dei modelli stessi (si pensi a Poisson o Negative Binomial). Possono anche essere calcolati da regressioni logistiche multinomiali dove le categorie o livelli di risposta sono tra di loro indipendenti. Allo stesso modo i dati di conteggio sono considerati indipendenti gli uni dagli altri.

La struttura base di un modello di conteggio è la seguente

$$\log(\mu) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n \quad \rightarrow \quad \mu = e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n}.$$

Da tale struttura emerge che la relazione tra μ e i predittori non è lineare; invece, si osserva una relazione lineare tra il logaritmo di μ e i predittori. Questa relazione lineare tra $\log(\mu)$ e il predittore lineare $x\beta$ è la stessa per tutti i principali modelli di conteggio ed è indicata come segue $\log(\mu) = x\beta$. Il link logaritmico adottato dai modelli di conteggio garantisce che i valori stimati dal modello siano sempre positivi ($\mu > 0$). Al contrario, la regressione lineare, non avrebbe garantito tale risultato.

I dati di conteggio, solitamente, derivano da osservazioni reali o da risultati di studi specifici. Per quanto riguarda i modelli statistici si può pensare ai dati di conteggio come realizzazioni di un processo che rappresenta i dati che stiamo modellizzando. L'obiettivo è quello di stimare i parametri di un modello con meno bias possibile, per poi utilizzare tali stime per prevedere le osservazioni di eventi reali esterni al modello, per esempio eventi futuri.

2.1.1 STIMA DEL MODELLO

Per stimare i modelli di conteggio abbiamo due metodi:

- a) Full Maximum Likelihood Estimation (MLE o FMLE)
- b) Iterative Reweighted Least Squares algorithm (IRLS).

Molti software non prevedono però l'utilizzo della prima delle due alternative sopra citate. Si noti inoltre che l'IRLS è una versione semplificata della massimizzazione di una funzione di verosimiglianza solitamente utilizzata per la stima dei GLM; a tal proposito possiamo far rientrare i principali modelli di conteggio, quali Poisson e Negative Binomial, in questo gruppo di modelli lineari generalizzati dal quale possiamo ottenere innumerevoli vantaggi.

L'IRLS nasce dall'algoritmo Fisher scoring, ma sostituisce alla matrice Hessiana osservata, che quest'ultimo utilizza, la matrice Hessiana attesa (matrice inversa dell'informazione attesa di Fisher). Ne risulta un'equazione chiamata Newton-Raphson che può essere scritta in termini di OLS. Questo algoritmo permette di calcolare una serie di modelli tra di loro correlati.

In sostanza entrambi i metodi prevedono la massimizzazione della funzione di verosimiglianza al fine di stimare i parametri del modello.

2.2 POISSON

Il modello di conteggio più utilizzato, come detto già più volte in precedenza, è il modello Poisson, sul quale sono basati vari altri modelli dello stesso genere. È stato il primo modello creato per la modellizzazione di dati di conteggio e ancora oggi è alla base della maggior parte dei modelli che li trattano. Il modello Poisson è considerabile un sottoinsieme di un modello Negative Binomial, che in seguito analizzeremo nello specifico. Dal momento che la distribuzione Poisson ha un importante ruolo, vediamo di seguito la sua derivazione e la sua struttura. Questa distribuzione viene definita dalla seguente funzione:

$$f(y_i; \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!}, \quad y_i = 0, 1, 2, \dots, n_i; \quad \lambda > 0,$$

dove la variabile casuale Y è la risposta conteggio (che specifica il conteggio di un determinato evento) e il parametro λ è la media della distribuzione, anche chiamata rate o parametro di intensità. Per convenzione molte volte λ viene anche indicata come μ , dal momento che le medie di tutti i GLM sono così definite e la Poisson appartiene a quest'ultimi.

Questa distribuzione potrebbe anche includere un parametro t associato alla media, che rappresenta l'area o il tempo in cui l'evento considerato occorre, chiamato esposizione. Se t è costante la distribuzione è la seguente:

$$f(y_i; \mu_i) = \frac{e^{-t_i \mu_i} (t_i \mu_i)^{y_i}}{y_i!}.$$

Se incluso nei dati, il logaritmo naturale di t può essere inserito come un offset nella stima del modello. Questo viene chiamato Rate Model, ma ne vedremo in seguito le caratteristiche nello specifico.

Dalla distribuzione Poisson si deriva chiaramente l'omonimo modello di regressione. Tale modello lineare generalizzato assume che $Y_i \sim \text{DE1}(\mu_i, V(\mu_i) = \mu_i, h(\phi) = 1)$ con $\mu_i > 0$, cioè che la variabile casuale Y_i appartenga alla famiglia di dispersione esponenziale con media e varianza pari a μ_i e parametro di dispersione costante e pari a 1. La relazione tra il valore atteso μ , i coefficienti β e i predittori x è rappresentata in questo modo: $\mu = \exp(x\beta)$ (che equivale a scrivere $\log(\mu) = \eta$) dove μ è la media fittata del modello e $x\beta$ è il predittore lineare η con β che indica i parametri e x le covariate del modello.

Molto importante in questo modello è l'incidence rate ratio che è pari al rapporto tra un μ_i riferito a un determinato predittore e un nuovo μ_i riferito alla variazione unitaria dello stesso. Tale rapporto indica la variazione percentuale nella risposta media a fronte di una variazione di un'unità di una variabile a parità delle altre covariate. Ad esempio, se ho un μ_i che si riferisce a una determinata x_{i1} e un μ_i^{new} riferito all'aumento di 1 della stessa $x_{i1} + 1$, il rapporto $\frac{\mu_i^{\text{new}}}{\mu_i}$ sarà pari a $\exp(\beta_1)$ che indicherà l'aumento o la diminuzione percentuale nella variabile risposta a parità delle altre covariate a fronte di una variazione $\Delta x_{i1} = 1$.

Una caratteristica singolare della distribuzione Poisson è l'equidispersione, che prevede che la media e la varianza siano identiche. Questa relazione però si trova molto raramente nei dati e ciò ha portato alla specificazione di modelli di conteggio più generali che evitano quest'assunzione. Ogni evento in una distribuzione Poisson soggetto al processo di conteggio è indipendente dagli altri. Il fatto che ci siano y eventi in un periodo A non implica nulla sul conteggio degli eventi che ci saranno in un altro periodo B . Il tasso a cui gli eventi sono conteggiati in un dato periodo o area è μ con probabilità di occorrenza $\mu \cdot \text{lunghezza del periodo (o grandezza dell'area)}$.

Se le assunzioni di base di una Poisson non risultano essere rispettate, solitamente si è in una situazione di sovradisersione che, nella maggior parte dei casi, potrebbe essere solo apparente.

Il metodo più immediato di risoluzione di un problema di sovradisersione che viene dalla stima di una Poisson come GLM, è lo scaling degli standard errors.

I problemi di sovradisersione si possono estendere anche ai modelli Negative Binomial, dato che fondamentalmente anch'essi potrebbero essere sovradispersi.

Riconoscere le violazioni delle assunzioni della distribuzione può prevenire la perdita di tempo derivante dalla stima di modelli per sovradisersione reale. Le seguenti sono tra le più comuni:

1. I dati non presentano zeri: in questi casi la distribuzione deve essere aggiustata in modo tale da rendere conto degli zeri mancanti usando Zero-truncated Poisson/Zero-truncated Negative Binomial. Chiaramente non sono utilizzati quando nei dati ha senso avere conteggi pari a zero.
2. I dati presentano troppi zeri: il numero degli zeri è molto maggiore di quello previsto dal modello (nella norma ci si aspetta che più grande è la media meno siano gli zeri); i modelli utilizzati in queste situazioni sono i

cosiddetti Zero-inflated Poisson/Zero-Inflated Negative Binomial. In questi modelli si ipotizza che i dati vengano da due distribuzioni distinte dove gli zeri strutturali di una distribuzione binaria si uniscono agli interi non negativi (inclusi gli zeri) di una distribuzione di conteggio. La distribuzione in questione diventa quindi

$$y \sim \begin{cases} 0 & \text{con probabilità } p \\ \text{Poisson}(\lambda) & \text{con probabilità } (1 - p) \end{cases}$$

$$P(Y_i = y_i) = \begin{cases} p_i + (1 - p_i)e^{-\mu_i} & \text{se } y_i = 0 \\ (1 - p_i)\frac{e^{-\mu_i}\mu_i^{y_i}}{y_i!} & \text{se } y_i > 0. \end{cases}$$

3. I dati sono separabili in due o più distribuzioni: quando i conteggi pari a 0 sembrano derivare da una fonte strutturale, si può pensare di separare la distribuzione in due parti; si usano a tal fine gli Hurdle models (anche noti come Zero-altered) che separano i dati in zeri e conteggi positivi con una componente binaria che assume valore 0 (zero) o 1 (conteggio positivo).
4. Osservazioni censurate: le osservazioni in questione contribuiscono al modello ma l'esatta informazione è mancante; ad esempio si chiede quando è stata la prima volta in cui si è svolta una determinata attività e il rispondente non ricorda l'età esatta (left censoring) o, in un altro scenario, un esperimento per mancanza di fondi si conclude in anticipo e le informazioni raccolte sono limitate al periodo in cui l'esperimento è stato condotto (right censoring).
5. Truncated data: le osservazioni in questione sono interamente escluse dal modello. Supponiamo, ad esempio, di avere a disposizione i pazienti che sono stati diagnosticati con una determinata malattia negli ultimi 5 anni. Questo significa che non possiamo includere i pazienti che sono morti prima di essere diagnosticati con tale malattia e che quindi non faranno parte dello studio in questione. Quindi, i pazienti che sono morti prima della diagnosi sono considerati troncati.
6. I dati sono strutturati come panel: dati clusterizzati e longitudinali; i dati consistono di un determinato numero di panel ma le osservazioni all'interno

di ciascuno di essi non possono essere considerate tra di loro indipendenti e ciò porta a una situazione di sovradisersione.

7. L'occorrenza di alcune risposte è basata sul valore di altre variabili; ad esempio si può pensare a delle informazioni riservate che le persone potrebbero volontariamente omettere.
8. Variabili endogene nel modello: ci sono variabili non comprese nel modello che influenzano indirettamente le variabili presenti nello stesso.

2.2.1 RELAZIONE TRA POISSON E BINOMIALE

Analizziamo ora, come precedentemente annunciato, la fondamentale relazione tra la distribuzione Poisson e quella Binomiale.

Prendiamo in considerazione la funzione di probabilità di una Binomiale, solitamente definita in questo modo

$$f(y; p, n) = \binom{n}{y} p^y (1-p)^{n-y},$$

dove y sono i successi di una Bernoulli, n il numero di prove e p la probabilità di successo; sapendo che la media di una Binomiale è pari a np e indicando tale media con λ , possiamo sostituire il parametro p all'interno della funzione di probabilità con λ/n . A questo punto per n che diverge a ∞ avremo :

$$\begin{aligned} \lim_{n \rightarrow \infty} f(y; p, n) &= \lim_{n \rightarrow \infty} \frac{n!}{y!(n-y)!} \left(\frac{\lambda}{n}\right)^y \left(1 - \frac{\lambda}{n}\right)^{n-y} \\ &= \lim_{n \rightarrow \infty} \frac{n!}{y!(n-y)!} \left(\frac{\lambda}{n}\right)^y \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-y} \\ &= \lim_{n \rightarrow \infty} \frac{\lambda^y n(n-1)(n-2) \dots (n-y+1)}{y! n^y} \left(1 - \frac{\lambda}{n}\right)^n \\ &= \frac{\lambda^y}{y!} \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n \\ &= \frac{\lambda^y}{y!} e^{-\lambda}. \end{aligned}$$

Quella che abbiamo ottenuto è la funzione di probabilità di una Poisson; pertanto la dimostrazione qui sopra illustra come al tendere di n a ∞ una distribuzione Binomiale tende a quella di Poisson.

2.2.2 POISSON COME ELEMENTO DELLA FAMIGLIA ESPONENZIALE

La distribuzione Poisson appartiene alla famiglia di dispersione esponenziale e, di conseguenza, ai Generalized Linear Models (GLM). Le distribuzioni appartenenti a tale famiglia possono essere tutte ricondotte a questa forma

$$f(y; \theta, \phi) = \exp \left\{ \frac{y \cdot \theta - c(\theta)}{h(\phi)} + d(y; \phi) \right\},$$

da cui derivo la funzione di verosimiglianza

$$L(\theta; y, \phi) = \prod_{i=1}^n \exp \left\{ \frac{y \cdot \theta - c(\theta)}{h(\phi)} + d(y; \phi) \right\}.$$

Dal momento che risultano di particolare interesse, definiamo gli elementi fondamentali di tale famiglia:

- la link function: che rappresenta la relazione lineare tra i predittori $x\beta$ e i valori fittati μ o $\hat{y}$
- la funzione generatrice dei cumulanti: determina tutti i momenti
- parametro naturale
- parametro di dispersione
- il link inverso: definisce i fitted values, anche indicato come η

In termini di famiglia di dispersione esponenziale sappiamo che la Poisson ha

$$\begin{aligned} \text{link} \quad \theta &= \log(\mu) = \eta = x\beta \\ \text{funzione generatrice dei cumulanti} \quad c(\theta) &= \mu \\ \text{link inverso} \quad \mu &= \exp(\eta) = \exp(x\beta) \end{aligned}$$

La media e la varianza di questa distribuzione, dal momento che questa appartiene alla famiglia di dispersione esponenziale, possono essere ottenute come derivata prima e derivata seconda della funzione generatrice dei cumulanti rispetto a θ . Infatti, prendendo la funzione generatrice dei cumulanti $c(\theta) = \exp(\theta)$ e derivandola rispetto a θ , otteniamo nuovamente $\exp(\theta)$, lo stesso si ripete identicamente per la derivata seconda. Sapendo però che $\mu = \exp(\theta)$, abbiamo dimostrato che effettivamente media e varianza sono uguali a μ .

Nello specifico, per la Poisson, che ha funzione di probabilità pari a

$$f(y_i; \mu_i) = \frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!}, \quad y_i = 0, 1, 2, \dots \text{ e } \mu > 0,$$

la funzione di verosimiglianza è

$$L(\mu_i; y_i, \phi) = \prod_{i=1}^n \exp \{y_i \log(\mu_i) - \mu_i - \log(y_i!)\}.$$

Dall'equazione precedente ricaviamo la log-verosimiglianza per la Poisson

$$l(\mu_i; y_i) = \sum_{i=1}^n \{y_i \log(\mu_i) - \mu_i - \log(y_i!)\} = \sum_{i=1}^n \{y_i (\mathbf{x}_i' \boldsymbol{\beta}) - \mathbf{x}_i' \boldsymbol{\beta} - \log(y_i!)\}$$

(talvolta la $y_i!$ è anche rappresentata come $\Gamma(y_i + 1)$).

La devianza di una distribuzione Poisson è

$$D = 2 \sum_{i=1}^n \{y_i \log(y_i) - y_i - y_i \log(\mu_i) + \mu_i\} = 2 \sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{\mu_i} \right) - (y_i - \mu_i) \right\}.$$

2.2.3 POISSON RATE MODEL

La Poisson può essere parametrizzata anche come di seguito:

$$f(y_i; \mu_i) = \frac{e^{-t_i \mu_i} (t_i \mu_i)^{y_i}}{y_i!},$$

dove, come abbiamo già detto, t rappresenta l'esposizione o lunghezza del tempo durante il quale l'evento accade (o l'area in cui l'evento accade). Ad esempio se il modello si basa su dati relativi a una malattia potrebbe essere il numero di persone ricoverate per quella determinata malattia in un determinato Paese. Dividendo in questo caso i ricoveri per la popolazione di quello specifico Stato, si ottiene il tasso di incidenza o IRR (incidence rate ratio).

Aggiustando la media di una Poisson per il tempo o l'area ottengo μ_i/t_i . Ne segue che il modello di regressione Poisson per l'atteso tasso di conteggio per unità di tempo si può scrivere come

$$\log(\mu_i/t_i) = \alpha + \mathbf{x}_i' \boldsymbol{\beta} \quad \rightarrow \quad \log(\mu_i) = \alpha + \mathbf{x}_i' \boldsymbol{\beta} + \log(t_i),$$

Pertanto incorporando l'intercetta in $x_i'\beta$ otteniamo che $\log(\mu_i/t_i) = x_i'\beta$ e applicando l'esponenziale a entrambe le parti dell'equazione ne risulta

$$\mu_i = \exp(x_i'\beta + \log(t_i)),$$

In parole povere, un modello Poisson è identico a un rate model ma stima il numero di conteggi in un dato periodo/area. Se quest'ultimi hanno valore pari a 1 otteniamo chiaramente un modello Poisson standard, se invece hanno valore maggiore di 1 sono incorporate nel modello tramite un offset che riflette il tempo o l'area in cui il conteggio è generato. Prima di essere inserito nel modello bisogna però eseguire il logaritmo dell'offset.

2.3 SOVRADISPERSIONE

In un modello Poisson per sovradisersione si intende una situazione nella quale la varianza risulta essere molto più grande della media, pertanto l'ipotesi di equidispersione di tale modello non è più verificata. La maggior parte delle volte che si parla di sovradisersione ci si riferisce a sovradisersione Poisson. Essa è causata da una correlazione positiva tra le risposte o da qualsiasi eccesso di variazione tra le probabilità o i conteggi della risposta. Può realizzarsi anche in qualsiasi altro caso di violazione delle ipotesi alla base della distribuzione in questione. Un modello che non riesce a adattarsi in maniera adeguata a dati sovradispersi è anch'esso chiamato sovradisperso.

La sovradisersione implica che le deviazioni standard siano seriamente sotto-stimate, dunque alcuni predittori potrebbero risultare significativi quando in realtà non lo sono, cioè potrebbe portare a inferenze errate per i parametri di regressione.

In un senso più generale, talvolta, con sovradisersione, si intende che la varianza osservata della risposta conteggio è maggiore di quella attesa (predicted/stimata dal modello).

Per verificare l'ipotesi di sovradisersione, solitamente viene utilizzata la statistica di Pearson

$$\chi^2 = \sum_{i=1}^n \frac{(y_i - \bar{y}_n)^2}{\bar{y}_n},$$

che rapportata a $n - 1$ ci restituisce l'*indice di dispersione di Fisher*. Se questo indice risulta maggiore di uno, è molto probabile che ci si trovi davanti a un caso di sovradisersione.

La sovradisersione potrebbe anche essere apparente, in tal caso potrebbe essere dovuta a diverse ragioni come ad esempio: omissione da parte del modello di covariate importanti, inclusione nei dati di molti outliers o insufficiente numero di termini di interazione nel modello.

Esistono vari modelli specifici per trattare la sovradisersione, che nascono da possibili meccanismi alternativi per il processo sottostante. Categorizziamo quelli principali in due gruppi:

- i. quelli che assumono una forma più generale per la funzione di varianza, includendo, nella maggior parte dei casi, parametri aggiuntivi;
- ii. quelli che assumono un modello a due stadi per la risposta, ipotizzando che il parametro della distribuzione in questione abbia anch'esso una distribuzione.

I modelli che rientrano nel primo gruppo non fanno riferimento a una specifica distribuzione di probabilità per la variabile risposta, ma possono essere viste come utili estensioni del modello di base. I parametri di regressione in questi casi vengono stimati con una funzione di quasi-verosimiglianza con dei metodi studiati per la stima di parametri in più nella funzione di varianza.

Il secondo tipo di modelli rappresenta dei modelli di probabilità per la variabile risposta di tipo composto. Solitamente, però, la distribuzione composta assume forme complicate. In questo gruppo rientra chiaramente la Negative Binomial, che tra poco andremo ad analizzare nello specifico.

2.3.1 QUASI-VEROSIMIGLIANZA POISSON

Il metodo di quasi-verosimiglianza (QL), per prima sviluppato da Wedderburn nel 1974, è basato sui GLM ma permette di calcolare le stime dei parametri a partire solo da specifiche riguardanti la media e la varianza delle osservazioni alla base del modello, senza restringere il campo alle sole distribuzioni DE_1 . Dalla prima definizione sono state fatte delle generalizzazioni portate avanti da Nelder e Pregibon. Questa generalizzazione del modello di partenza è chiamata Extended Quasi-Likelihood (EQL o quasi-verosimiglianza estesa) e permette di valutare l'adeguatezza della varianza della quasi-verosimiglianza.

I modelli QL permettono di modellizzare i dati senza specificare la funzione di log-verosimiglianza a essi sottostante. Si inizia a partire da una media e una funzione di varianza, non ristrette alle sole appartenenti alla famiglia di dispersione esponenziale, procedendo "all'indietro" verso una funzione implicita di log-verosimiglianza. Quest'ultima non viene derivata da una funzione di probabilità e proprio per questo viene chiamata quasi-verosimiglianza (che in realtà sarebbe una quasi-log-verosimiglianza). In pratica si tratta di calcolare l'integrale di una score-function per ottenere qualcosa di simile a una log-verosimiglianza. A questo punto la QL viene impiegata in un algoritmo IRLS per la stima dei parametri, esattamente come succede per i GLM.

La funzione di quasi-verosimiglianza viene genericamente definita nel seguente modo:

$$Q(\mu_i; y_i) = \int_{y_i}^{\mu_i} \frac{y_i - \mu_i}{\phi V(\mu_i)} d(\mu_i) \rightarrow Q(\mu, y) = \sum_{i=1}^n Q(\mu_i, y_i).$$

Allo stesso fine della QL, potrebbe essere definita anche una quasi-devianza così come segue

$$QD(\mu; y) = 2 \int_{y_i}^{\mu_i} \frac{y_i - \mu_i}{V(\mu_i)} d(\mu_i).$$

Per quanto riguarda la Poisson la quasi verosimiglianza risulta

$$Q_{POI}(\mu_i; y_i) = \sum_{i=1}^n \{y_i \log(\mu_i) - \mu_i\}$$

che è esattamente pari alla log-verosimiglianza della Poisson ma senza $\log(y_i)!$, che è il logaritmo del termine che assicura che le probabilità sommino a uno.

Per la Negative Binomial invece avremmo

$$Q_{NB2}(\mu_i; y_i) = \sum_{i=1}^n \left\{ y_i \log(\mu_i) - \frac{1 + \alpha y_i}{\alpha} \log(1 + \alpha \mu_i) \right\}.$$

Solitamente per dati sovradispersi Poisson si utilizza questo modello moltiplicando la varianza μ per un valore costante indicato come ψ (scaling della varianza). Il fatto che la varianza sia moltiplicata per una costante cambia la funzione di verosimiglianza (o la devianza), che viene divisa per un fattore scale.

2.4 NEGATIVE BINOMIAL

Approfondiamo adesso il metodo di derivazione e di stima della Negative Binomial e come essa sia utile a modellizzare dati di conteggio. Vedremo anche come questa può essere modificata per adattarsi a molte situazioni diverse tra di loro.

La Negative Binomial più utilizzata, dati i grandi vantaggi dal punto di vista statistico e interpretativo che essa comporta, è la NB2 (anche chiamata Negative Binomial tradizionale o quadratica) e può essere pensata come un modello Poisson con eterogeneità Gamma dove il rumore Gamma ha media uno. Infatti, abbiamo già detto che, per dati di conteggio, un modello di regressione Poisson assume che la risposta sia realizzazione di una distribuzione con varianza pari alla media e, in termini di GLM, uguale a $g^{-1}(\mu_i) = x_i'\beta$. L'aggettivo quadratica deriva dall'esponente del secondo parametro della varianza della NB2 che è pari a $\mu + \alpha\mu^2$. Aggiungiamo anche che la NB2 può essere ottenuta da una trasformazione della NB-C, o Negative Binomial canonica. Quest'ultima è direttamente derivabile dalla funzione di probabilità della Negative Binomial, nello specifico si tratta degli y fallimenti prima dell' r -esimo successo in una serie di prove indipendenti Bernoulli. Sia y che r sono, solitamente, considerati interi (distribuzione di Pascal). Se r può assumere qualsiasi valore reale positivo si parla di distribuzione di Polya, questa distribuzione fa sì che il modello sia più flessibile; infatti i sta anche ad indicare l'eccesso di correlazione tra i dati, limitarlo a un numero intero eliminerebbe la natura continua della correlazione stessa. In entrambi i casi si tratta comunque di forme della distribuzione Negative Binomial.

Pertanto al fine di costruire un modello di regressione che tenga conto della sovradisersione rispetto al modello di regressione Poisson, si costruisce un modello Negative Binomial. In generale un modello Negative Binomial tradizionale, NB2, può essere esplicitato nel seguente modo:

$$\begin{cases} Y|\lambda \sim \text{Poisson}(\lambda\mu) \\ \lambda \sim \text{Gamma}(k, k) \end{cases} \rightarrow Y \sim \text{NB2}(\mu, k)$$

dove $\mu > 0$ e $\lambda > 0$.

Tale modello parte dall'ipotesi che $y_1, \dots, y_n$ siano realizzazioni di variabili casuali indipendenti Y_i con $i = 1, \dots, n$, aventi distribuzione marginale ricavabile

da una mistura Poisson-Gamma come segue:

$$\begin{aligned}
 f(y_i; \mu, k) &= \int_0^\infty \frac{e^{-\lambda_i \mu} (\lambda_i \mu)^{y_i}}{y_i!} \frac{k^k \lambda_i^{k-1} e^{-k\lambda_i}}{\Gamma(k)} d(\lambda_i) \\
 &= \frac{\mu^{y_i}}{\Gamma(y_i + 1)} \frac{k^k}{\Gamma(k)} \int_0^\infty e^{-\lambda_i(\mu+k)} \lambda_i^{(y_i+k)-1} d(\lambda_i) \\
 &= \frac{\mu^{y_i}}{\Gamma(y_i + 1)} \frac{k^k}{\Gamma(k)} \int_0^\infty e^{-\lambda_i(\mu+k)} \left(\frac{t_i}{\mu+k} \right)^{(y_i+k)-1} d\left(\frac{t_i}{\mu+k} \right) \\
 &= \frac{\mu^{y_i}}{\Gamma(y_i + 1)} \frac{k^k}{\Gamma(k)} \left(\frac{1}{\mu+k} \right)^{y_i+k} \int_0^\infty e^{-t_i} t_i^{(y_i+k)-1} d(t_i) \\
 &= \frac{\Gamma(y_i + k)}{\Gamma(y_i + 1)\Gamma(k)} \left(\frac{\mu/k}{1 + \mu/k} \right)^{y_i} \left(\frac{1}{1 + \mu/k} \right)^k.
 \end{aligned}$$

Per comodità, ciò che abbiamo appena calcolato può anche essere espresso in questo modo:

$$f(y_i; \mu, \alpha) = \frac{\Gamma(y_i + 1/\alpha)}{\Gamma(y_i + 1)\Gamma(1/\alpha)} \left(\frac{\mu\alpha}{1 + \mu\alpha} \right)^{y_i} \left(\frac{1}{1 + \mu\alpha} \right)^{1/\alpha},$$

dove $\alpha = 1/k$ ha una relazione direttamente proporzionale con la sovradisersione della Poisson e non più indiretta come succedeva per k . In questo caso specifichiamo che α è il parametro ancillare dell'eterogeneità e non va confuso con la sovradisersione statistica (con la quale abbiamo detto che ha un rapporto diretto), che può essere calcolata, come abbiamo visto nel capitolo precedente, attraverso il rapporto tra l'indice di Pearson e i gradi di libertà del modello.

Alle volte, sapendo che $\Gamma(n + 1) = n!$, il rapporto tra le funzioni Gamma è espresso come un coefficiente binomiale. In pratica:

$$f(y_i; \mu, \alpha) = \binom{y_i + \frac{1}{\alpha} - 1}{\frac{1}{\alpha} - 1} \left(\frac{\mu\alpha}{1 + \mu\alpha} \right)^{y_i} \left(\frac{1}{1 + \mu\alpha} \right)^{1/\alpha}$$

dove, per $k = 1/\alpha$ intero

$$\binom{y_i + \frac{1}{\alpha} - 1}{\frac{1}{\alpha} - 1} = \frac{\Gamma(y_i + 1/\alpha)}{\Gamma(y_i + 1)\Gamma(1/\alpha)} = \frac{(y_i + \frac{1}{\alpha})!}{y_i! (\frac{1}{\alpha} - 1)!}$$

A questo punto possiamo calcolare la funzione di verosimiglianza che sarà pari a

$$L(\mu_i; y_i, \alpha) = \prod_{i=1}^n \exp \left\{ y_i \log \left(\frac{\alpha \mu_i}{1 + \alpha \mu_i} \right) - \frac{1}{\alpha} \log(1 + \alpha \mu_i) + \log \Gamma \left(y_i + \frac{1}{\alpha} \right) - \log \Gamma(y_i + 1) - \log \Gamma \left(\frac{1}{\alpha} \right) \right\},$$

da cui si ricava facilmente, applicando il logaritmo, la log-verosimiglianza

$$l(\mu_i; y_i, \alpha) = \sum_{i=1}^n \left\{ y_i \log \left(\frac{\alpha \mu_i}{1 + \alpha \mu_i} \right) - \frac{1}{\alpha} \log(1 + \alpha \mu_i) + \log \Gamma(y_i + \frac{1}{\alpha}) - \log \Gamma(y_i + 1) - \log \Gamma(\frac{1}{\alpha}) \right\}.$$

Facendo particolare attenzione a μ_i , possiamo dire che esso è $\mu_i = g^{-1}(x_i' \beta) = \exp(x_i' \beta)$ (esattamente come per la Poisson) quindi, sostituendo nell'equazione precedente, in termini di coefficienti β risulta

$$l(\mu_i; y_i, \alpha) = \sum_{i=1}^n \left\{ y_i \log \left(\frac{\alpha \exp(x_i' \beta)}{1 + \alpha \exp(x_i' \beta)} \right) - \frac{1}{\alpha} \log(1 + \alpha \exp(x_i' \beta)) + \log \Gamma \left(y_i + \frac{1}{\alpha} \right) - \log \Gamma(y_i + 1) - \log \Gamma \left(\frac{1}{\alpha} \right) \right\}.$$

Sappiamo già che, per la stima dei coefficienti del modello tramite massima verosimiglianza, si calcola il gradiente della log-verosimiglianza derivata rispetto a β e lo si pone uguale a zero. Anche se solitamente è inserito come costante nel GLM, se α fosse da stimare si dovrebbe calcolare la derivata rispetto a tale parametro e porre anch'essa uguale a zero.

A questo punto, per costruire il nostro algoritmo IRLS, abbiamo bisogno della matrice dell'informazione attesa che per la NB2; quest'ultima, al contrario di ciò che succede con la NB-C e la Poisson, non coincide con la matrice Hessiana delle derivate seconde parziali.

La matrice dell'informazione attesa è calcolabile a partire da quella di varianza e covarianza facendone l'inversa. Le deviazioni standard si calcolano facendo la radice quadrata degli elementi sulla diagonale della suddetta matrice di varianza-covarianza, ma solitamente non differiscono di troppo da quelli calcolati con la matrice Hessiana.

Ribadiamo che l'algoritmo Netwon-Raphson usa la matrice dell'informazione attesa, mentre l'originale IRLS basato sul Fisher scoring usa quella dell'informa-

zione osservata.

Procediamo, per quanto esplicitato prima, a calcolare le derivate prime e seconde.

$$\begin{aligned}
\frac{\partial l}{\partial \beta} &= \sum_{i=1}^n \frac{x_i(y_i - \mu_i)}{1 + \alpha \mu_i} \\
\frac{\partial l}{\partial \alpha} &= \sum_{i=1}^n \left[\frac{1}{\alpha^2} \left(\log(1 + \alpha \mu_i) + \frac{\alpha(y_i - \mu_i)}{1 + \alpha \mu_i} \right) + \psi \left(y_i + \frac{1}{\alpha} \right) - \psi \left(\frac{1}{\alpha} \right) \right] \\
\frac{-\partial^2 l}{\partial \beta \partial \beta'} &= \sum_{i=1}^n \frac{\mu_i (1 + \alpha y_i)}{(1 + \alpha \mu_i)^2} x_i x_i' \\
\frac{-\partial^2 l}{\partial \beta \partial \alpha} &= \sum_{i=1}^n \frac{\mu_i (y_i - \mu_i)}{(1 + \alpha \mu_i)^2} x_{ij} \\
\frac{\partial^2 l}{\partial \alpha^2} &= \sum_{i=1}^n \left[-\frac{1}{\alpha^3} \left(\frac{\alpha(1 + 2\mu_i)(y_i - \mu_i) - \alpha \mu_i (1 + \alpha \mu_i)}{(1 + \alpha \mu_i)^2} + 2 \log(1 + \alpha \mu_i) \right) \right. \\
&\quad \left. + \psi' \left(y_i + \frac{1}{\alpha} \right) + \psi' \left(\frac{1}{\alpha} \right) \right]
\end{aligned}$$

Per approssimare la derivata prima (ψ) e seconda (ψ') del logaritmo della funzione Γ vengono utilizzate, rispettivamente, la Digamma e la Trigamma.

Il valore atteso della derivata mista è pari a zero, quindi per fare inferenza su β possiamo fare solo riferimento alle derivate a esso relative in quanto β e α risultano tra di loro indipendenti.

2.4.1 NEGATIVE BINOMIAL COME GLM

Le due rappresentazioni più utilizzate per la Negative Binomial sono la NB-C (forma canonica) e la NB2 (forma tradizionale). Quest'ultima può essere considerata una trasformazione della prima in una forma con link logaritmico e ci permette un confronto diretto con la Poisson, che è una NB2 con $\alpha = 0$. Come abbiamo già detto la forma canonica, derivabile direttamente dalla funzione di probabilità della Negative Binomial, può essere descritta come la probabilità di osservare y fallimenti prima dell' r -esimo successo in una serie di prove Bernoulliane, dove r solitamente è un intero positivo. Si vede facilmente come questa forma sia riconducibile a quella di una Binomiale (da qui si deduce anche perché la Negative Binomial è stata così denominata) che, però, descrive il numero di successi in n prove. Sapendo che la funzione di probabilità di una Binomiale può essere espressa in questo modo: $\binom{n}{y} p^y (1-p)^{n-y}$, dove chiaramente p è la

probabilità di successo, possiamo fissare $p = 1/(1 + \alpha\mu_i)$ e $k = 1/\alpha$ per esprimere la funzione di probabilità della Negative Binomial come

$$f(y_i; p_i, z) = \binom{y_i + z - 1}{z - 1} p_i^z (1 - p_i)^{y_i}$$

enfaticizzando il rapporto che essa ha con la Binomiale.

Da qui possiamo convertirla direttamente nella forma standard per la **famiglia esponenziale**

$$f(y_i; p_i, z) = \exp \left\{ y_i \log(1 - p_i) + z \log(p_i) + \log \binom{y_i + z - 1}{z - 1} \right\}$$

in cui $\theta_i = \log(1 - p_i)$ è il link e $c(\theta_i) = -z \log(p_i)$ è la funzione generatrice dei cumulanti e il parametro di dispersione è pari a 1.

A questo punto esplicitiamo la devianza di una Negative Binomial che è pari a

$$D = 2 \sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{\mu_i} \right) - \left(\frac{1}{\alpha} + y_i \right) \log \left(\frac{1 + \alpha y_i}{1 + \alpha \mu_i} \right) \right\}$$

Dunque per la Negative Binomial Canonica NB-C, in termini di GLM, data la seguente equazione

$$f(y_i; \mu_i, \alpha) = \binom{y_i + \frac{1}{\alpha} - 1}{\frac{1}{\alpha} - 1} \left(\frac{\mu_i \alpha}{1 + \mu_i \alpha} \right)^{y_i} \left(\frac{1}{1 + \mu_i \alpha} \right)^{1/\alpha}$$

riparametrizzata in termini di μ e α , e quindi data la forma della famiglia esponenziale, ossia

$$f(y_i; \mu_i, \alpha) = \exp \left\{ y_i \log \left(\frac{\alpha \mu_i}{1 + \alpha \mu_i} \right) - \frac{1}{\alpha} \log(1 + \alpha \mu_i) + \log \binom{y_i + \frac{1}{\alpha} - 1}{\frac{1}{\alpha} - 1} \right\}$$

calcoliamo i termini utili all'algoritmo IRLS

$$\text{link } g(\mu_i) = \theta_i = \log \left(\frac{\alpha \mu_i}{1 + \alpha \mu_i} \right)$$

$$\text{link inverso } g^{-1}(\theta_i) = \mu_i = \frac{1}{\alpha(\exp(-\theta_i) - 1)} = \frac{1}{\alpha \exp(x_i' \beta) - 1}$$

$$\text{generatrice dei cumulanti } c(\theta_i) = \frac{1}{\alpha} \log(1 + \alpha \mu_i) = \frac{1}{\alpha} \log \left(\frac{e^{-\theta_i}}{e^{-\theta_i} - 1} \right)$$

e ricaviamo dalle suddette quantità la media e la varianza della distribuzione attraverso la derivata prima e la derivata seconda della funzione generatrice dei cumulanti.

$$c'(\theta_i) = \frac{\partial c}{\partial \theta_i} = \frac{1}{\alpha} \frac{\exp(-\theta_i) - 1}{\exp(-\theta_i)} \frac{\exp(-\theta_i)}{(\exp(-\theta_i) - 1)^2} = \frac{1}{\alpha(\exp(-\theta_i) - 1)} = \mu_i$$

$$c''(\theta_i) = \frac{\partial c'}{\partial \theta_i} = \frac{1}{\alpha} \frac{\exp(-\theta_i)}{(\exp(-\theta_i) - 1)^2} = \mu_i + \alpha \mu_i^2 = V(\mu_i)$$

Nell'algoritmo IRLS si usa solitamente una parametrizzazione in termini di μ , in altri algoritmi come, ad esempio, Newton-Raphson (o comunque algoritmi di massima verosimiglianza) si preferisce una parametrizzazione in termini di $x'_i \beta$.

ANDAMENTO DELLA NB₂ AL VARIARE DI α E μ

Inseriamo nella pagina seguente dei grafici per analizzare l'andamento della distribuzione in questione al variare dei parametri μ e α .

In Figura 2.1 possiamo osservare come, indipendentemente dal valore di μ , la distribuzione di una Negative Binomial tradizionale o quadratica all'aumentare di α si appiattisce sempre di più e assegna maggior probabilità verso valori molto prossimi allo zero. Nella Figura 2.2, invece, possiamo notare come, indipendentemente da α , per μ più piccoli le distribuzioni sembrano sovrapporsi molto di più, mentre, all'aumentare della media i valori vicini allo zero avranno probabilità minore.




Figura 2.1: Distribuzione di una NB₂ al variare di α




Figura 2.2: Distribuzione di una NB2 al variare di μ

2.4.2 NEGATIVE BINOMIAL LINEARE O NB1

La Negative Binomial lineare (NB1), come già detto in precedenza più volte, si distingue dalla Negative Binomial tradizionale (NB2) per l'esponente del secondo parametro della varianza. Infatti la varianza della NB1 risulta essere $\mu + \alpha\mu$ mentre quella della NB2 era $\mu + \alpha\mu^2$. Il quadrato di quest'ultima μ classifica la NB2 come quadratica, al contrario, la NB1 è indicata come lineare. Queste due forme di Negative Binomial possono essere anche ottenute come sottoinsiemi della NBP che ha varianza pari a $\mu + \alpha\mu^p$ sostituendo 1 e 2 all'esponente p .

Mettendo in evidenza μ , nella varianza della NB1, risulta $\mu(1 + \alpha)$ che mostra come il parametro della varianza della Poisson, μ , sia moltiplicato per $1 + \alpha$; se facessimo lo stesso per la NB2 otterremmo $\mu(1 + \alpha\mu)$. Questo fa risaltare l'evidente relazione tra la Negative Binomial e la Poisson.

Se nella stima della NB1 α fosse inserito come costante avremmo che il modello corrisponde a una quasi-verosimiglianza Poisson, sapendo che quest'ultima ha varianza pari a $\mu\phi$.

Anche la NB1 può essere derivata da una mistura Poisson-Gamma ma non nello stesso modo di una NB2. In questo caso abbiamo che

$$\begin{cases} Y_i \sim \text{Poisson}(\lambda_i) = f(y_i; \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!} \\ \lambda_i \sim \text{Gamma}(\delta, \mu_i) \end{cases}$$

e, sapendo che vale comunque $\mu_i = \exp(x_i \beta)$ e che il valore atteso e la varianza della Gamma sono rispettivamente pari a $\frac{\mu_i}{\delta} = \frac{\exp(x_i \beta)}{\delta}$ e $\frac{\mu_i}{\delta^2} = \frac{\exp(x_i \beta)}{\delta^2}$, la mistura risultante è pari a:

$$f(y_i) = \int_0^\infty \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!} \frac{\delta^{\mu_i} \lambda_i^{\mu_i-1}}{\Gamma(\mu_i)} e^{-\lambda_i \delta} d\lambda_i$$

e, integrandola rispetto a λ_i si ottiene:

$$\begin{aligned} f(y_i; \mu_i) &= \frac{\delta^{\mu_i}}{\Gamma(y_i + 1) \Gamma(\mu_i)} \int_0^\infty \lambda_i^{y_i + \mu_i - 1} e^{-\lambda_i(\delta+1)} d(\lambda_i) \\ &= \frac{\delta^{\mu_i}}{\Gamma(y_i + 1) \Gamma(\mu_i)} \int_0^\infty \left(\frac{t_i}{\delta + 1} \right)^{y_i + \mu_i - 1} e^{-t_i} d\left(\frac{t_i}{\delta + 1} \right) \\ &= \frac{\delta^{\mu_i}}{\Gamma(y_i + 1) \Gamma(\mu_i)} \frac{1}{(\delta + 1)^{y_i + \mu_i}} \int_0^\infty t_i^{y_i + \mu_i - 1} e^{-t_i} d(t_i) \\ &= \frac{\delta^{\mu_i}}{\Gamma(y_i + 1) \Gamma(\mu_i)} \frac{\Gamma(y_i + \mu_i)}{(\delta + 1)^{y_i + \mu_i}} = \frac{\Gamma(y_i + \mu_i)}{\Gamma(y_i + 1) \Gamma(\mu_i)} \left(\frac{\delta}{\delta + 1} \right)^{\mu_i} \left(\frac{1}{\delta + 1} \right)^{y_i}. \end{aligned}$$

La media e la varianza di una NB1 sono

$$\begin{aligned} E(Y_i) &= \frac{\exp(x_i \beta)}{\delta} \\ V(Y_i) &= \frac{\exp(x_i \beta)(1 + \delta)}{\delta^2} \end{aligned}$$

e, come si può facilmente calcolare, il rapporto varianza media è costante per tutte le osservazioni ed è pari a $\frac{1 + \delta}{\delta}$. Definendo α come $1/\delta$ otteniamo la stessa distribuzione in termini più familiari:

$$f(y_i; \mu_i) = \frac{\Gamma(y_i + \mu_i)}{\Gamma(y_i + 1) \Gamma(\mu_i)} \left(\frac{1}{1 + \alpha} \right)^{\mu_i} \left(\frac{\alpha}{1 + \alpha} \right)^{y_i}.$$

In termini di log-verosimiglianza otteniamo dunque

$$l(\mu_i, \alpha; y_1, \dots, y_n) = \sum_{i=1}^n [\log(\Gamma(y_i + \mu_i) - \log(\Gamma(y_i + 1)) - \log(\Gamma(\mu_i)) + y_i \log(\alpha) - (y_i + \mu_i) \log(1 + \alpha)].$$

2.4.3 ALTRE FORME DI NEGATIVE BINOMIAL

Vediamo di seguito, per completezza, altre forme di relativa importanza della Negative Binomial.

La prima di queste è la geometrica, già citata in precedenza la geometrica è una NB2 o una NB-C con parametro $\alpha = 1$, il che vuol dire che può essere derivata da entrambe le forme sopracitate. Può essere intesa come la probabilità di osservare y fallimenti prima del primo successo in una serie di prove indipendenti Bernoulli. Di solito viene rappresentata nel seguente modo

$$f(y; p) = p(1 - p)^y, \quad y = 0, 1, \dots, n \rightarrow f(y_i; p_i) = \exp[y_i \log(1 - p_i) + \log(p_i)]$$

dove la seconda rappresentazione è nella forma delle distribuzioni della famiglia di dispersione esponenziale. In questo caso il link e la funzione generatrice dei cumulanti sono, rispettivamente, $\theta_i = \log(1 - p_i)$ e $c(\theta_i) = -\log(p_i)$. E, derivando la funzione generatrice dei cumulati rispetto a θ , otteniamo:

$$\begin{aligned} \text{media } \mu_i &= \frac{1 - p_i}{p_i} \\ \text{varianza } V(\mu_i) &= \frac{1 - p_i}{p_i^2} = \mu_i(1 + \mu_i). \end{aligned}$$

Il tutto può essere parametrizzato anche in termini di μ ottenendo funzione di probabilità

$$f(y_i; \mu_i) = \frac{1}{1 + \mu_i} \left(\frac{\mu_i}{1 + \mu_i} \right)^{y_i}$$

e rispettiva funzione di log-verosimiglianza

$$l(\mu_i; y_1, \dots, y_n) = \sum_{i=1}^n y_i \log \left(\frac{\mu_i}{1 + \mu_i} \right) - \log(1 + \mu_i).$$

Per concludere analizziamo adesso la Negative Binomial bivariata. Essa, come tutti i modelli bivariati, è connessa a due variabili di risposta, correlate tra di loro per un fattore ρ . Solitamente queste due variabili risposta sono due vettori

che restituiscono diverse caratteristiche dello stesso argomento in esame. Questi modelli non sono stati studiati a fondo anche se potenzialmente molto importanti, dal momento che possono far capire le relazioni tra due variabili di conteggio. L'equazione della funzione di probabilità di una Negative Binomial bivariata fu costruita per la prima volta da Marshall e Olkin [Marshall & Olkin \(1990\)](#) nel 1990 ed è la seguente:

$$f(y_1, y_2) = \frac{\Gamma(y_1 + y_2 + \alpha^{-1})}{y_1!y_2! + 1} \left(\frac{\mu_1}{\mu_1 + \mu_2 + 1} \right)^{y_1} \left(\frac{\mu_2}{\mu_1 + \mu_2 + 1} \right)^{y_2} \left(\frac{1}{\mu_1 + \mu_2 + 1} \right)^{\alpha^{-1}}.$$

Da quel momento sono state proposte altre parametrizzazioni e generalizzazioni della stessa ma non hanno un utilizzo molto diffuso; il modello più noto tra questi è il modello bivariato derivante da una mistura Poisson-log-Normale, che quindi utilizza una log-Normale al posto di una Gamma come avveniva per la NB2. Questa forma di Negative Binomial ha però uno svantaggio, infatti non esiste una forma chiusa per questo modello e per la stima dei parametri del modello stesso devono essere utilizzate forme di simulazione.

Capitolo 3

APPLICAZIONE

Per l'applicazione che andremo ad eseguire abbiamo bisogno di dati di conteggio e, a tal proposito, prendiamo in considerazione i dati ufficiali riguardanti il COVID-19 disponibili sul sito dell'Unione Europea (per ulteriori informazioni sul dataset fare riferimento al sito [Ecdc \(2023\)](#)).

I dati sono stati raccolti dal centro Europeo per la prevenzione e il controllo delle malattie (ECDC) e contengono le informazioni riguardanti casi e decessi dovuti alla pandemia, dalla seconda settimana del 2020 alla quarantasettesima del 2023. Fino al 14 febbraio 2020, i dati venivano raccolti quotidianamente, ma questa pratica è stata interrotta e adesso i dati vengono raccolti e pubblicati settimanalmente. L'ECDC continua a monitorare la situazione raccogliendo informazioni da varie fonti ufficiali, comprese le autorità sanitarie nazionali, l'OMS e social media ufficiali.

Il dataset di partenza conteneva 12648 osservazioni e 7 variabili:

- *country*: Paese di rilevazione dei dati, variabile factor
- *country code*: codice dello Stato; avendo anche a disposizione il nome degli Stati questa variabile non aggiunge informazioni rilevanti al dataset
- *continent*: continente a cui appartiene lo Stato; dal momento che stiamo considerando solo dati relativi all'Europa questo dato è uguale per tutte le osservazioni e non sarà utilizzato in seguito
- *population*: numero di residenti nel Paese, variabile quantitativa
- *indicator*: indicatore che può assumere i valori *cases* e *deaths* a seconda dell'unità statistica considerata, variabile factor

- *weekly count*: conteggio settimanale di casi o morti, variabile quantitativa
- *year week*: anno e settimana a cui fanno riferimento i dati, assume valori dalla seconda settimana del 2020 alla 47esima del 2023 (esempio: la prima settimana del 2022 è indicata come 2022-1)
- *rate 14 day*: tasso di incidenza cumulativa a 14 giorni di nuovi casi o decessi (conteggio cumulato diviso per la popolazione e moltiplicato per 100000), variabile quantitativa
- *cumulative count*: conteggio cumulato di casi o decessi, variabile quantitativa
- *source*: fonte da cui sono stati ricavati i dati; nel dataset è per tutti i record pari a The European Surveillance System (TESSy) quindi non verrà utilizzata in seguito
- *note*: probabilmente colonna destinata alle note aggiuntive ma nel dataset preso in considerazione essa è composta da soli missing, pertanto non sarà considerata nelle analisi successive.

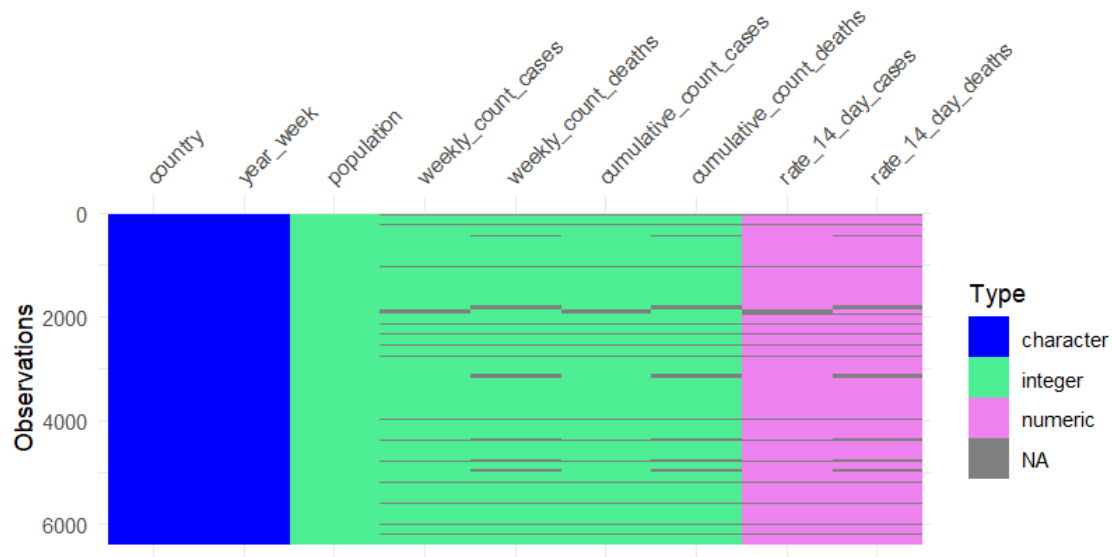


Figura 3.1: Grafico missing per ogni variabile

Nella fase di preprocessing, per praticità, il dataset è stato trasformato. Per prima cosa sono state rimosse le colonne *country code*, *continent*, *source* e *note* per le diverse motivazioni sopra elencate. In seguito si è utilizzata la colonna *indicator* per dividere le restanti variabili quantitative, tolte l'anno e la popolazione, in

modo tale che ogni colonna si riferisse solo ai casi o alle morti. Pertanto il dataset risultante contiene 6407 osservazioni e 9 variabili quali: *country*, *population*, *year*, *week*, *weekly count cases*, *weekly count deaths*, *rate 14 day cases*, *rate 14 day deaths*, *cumulative count cases* e *cumulative count deaths*.

A questo punto, da una prima attenta osservazione del grafico 3.1, vediamo che le unità statistiche contenenti dati mancanti sono solo una minima parte di tutto il dataset (con precisione rappresentano il 5.5% dei dati), quindi consideriamo per le analisi successive i soli record completi.

3.1 ANALISI DESCRITTIVE

Prima di iniziare con le analisi descrittive, possiamo notare che tra i Paesi presenti nel dataset abbiamo anche l'Europa, che rappresenta il totale di tutti gli altri Stati; questo potrebbe influenzare, anche di molto, tutti i modelli che andremo a stimare sui dati. Quindi, da ora in poi, considereremo due dataset, uno dei quali non conterrà le unità statistiche riferite al totale europeo.




Figura 3.2: Grafico delle correlazioni tra le variabili

Da un'analisi iniziale delle correlazioni tra variabili, come si può ben vedere dal

grafico 3.2, si evince che tutte le variabili sono tra di loro correlate positivamente, al netto delle variabili *cumulative count cases* e *rate 14 day deaths* che risultano leggermente correlate negativamente. Al contrario, le variabili che risultano tra di loro più correlate, come si poteva anche immaginare, sono i conteggi cumulati dei casi e delle morti.

Prima di proseguire con analisi specifiche vediamo un po' l'andamento di tutte le variabili quantitative presenti nel dataset.




Figura 3.3: Boxplot delle variabili Normalizzate

Dai boxplot 3.3 si evince che, nonostante tutte le variabili in questione siano state normalizzate, la mediana risulta comunque per ciascuna di esse molto prossima allo zero. Questo indica forse un'eccessiva quantità di zeri che dovremmo prendere in considerazione per successive analisi. Ognuna delle variabili presenta inoltre innumerevoli outliers. La feature con maggior variabilità è *rate 14 day deaths*, mentre quelle meno variabili sono i conteggi settimanali dei casi e delle morti, cioè *weekly count cases* e *weekly count deaths*.

Dal momento che i modelli saranno calcolati utilizzando come variabile risposta i conteggi settimanali delle morti, cioè la variabile *weekly count deaths*, analizziamo con un test e poi graficamente l'andamento della variabile in questione, per vedere se effettivamente essa si distribuisca come una Poisson. Il test di Kolmogorov-Smirnov eseguito sulla variabile in questione, ci restituisce un

p-value molto prossimo allo zero quindi essa non si distribuisce marginalmente come una Poisson. Stessa cosa si può evincere dalla rappresentazione grafica nella figura 3.4 che raffigura istogramma e kernel density della variabile in esame. Tuttavia dal momento che essa rappresenta un dato di **conteggio** settimanale delle morti, utilizzeremo comunque un modello Poisson per valutarne la sovradisersione e poi, in caso essa fosse verificata, stimeremo altri modelli, per gestire al meglio quest'ultima.




Figura 3.4: Distribuzione della variabile *weekly count deaths* con densità non parametrica

3.2 STIMA DEI MODELLI

Prima di procedere con l'applicazione dei modelli procediamo con la divisione del dataset in training e test, facendo in modo che il training comprenda l'80% dei dati a nostra disposizione. Per tener conto anche del tempo, riportato nella variabile *year yeek*, il test contiene il 20% del dataset corrispondente alle osservazioni più recenti e, di conseguenza, il training comprende il restante 80%. Nello specifico il training contiene 4501 osservazioni e il test le altre 1126.

3.2.1 STIMA DEL MODELLO POISSON

Come già detto in precedenza, a questo punto, applichiamo ai dati di training un modello **Poisson**, utilizzando la variabile *weekly count deaths* come variabile

risposta. Il modello, calcolato attraverso la funzione `glm`, restituisce tutti i coefficienti significativi almeno all'1% e una devianza pari a 8825923 con 4500 gradi di libertà (con devianza residua pari a 550437 con 4464 gradi di libertà). I risultati finora trovati ci suggeriscono che potrebbe esserci **sovradisersione**. Infatti, la devianza risulta essere di molto più grande rispetto ai gradi di libertà e i coefficienti forse "troppo" significativi, il che indica che potrebbero essere state sottostimate le deviazioni standard e ciò potrebbe portare a inferenze errate per i vari parametri. A tal proposito calcoliamo il coefficiente di sovradisersione con la statistica di Pearson rapportata ai gradi di libertà; esso è pari a 111.6973 pertanto il modello risulta sovradisperso.

Per completezza, facciamo anche un test per verificare gli outliers del modello e, dopo averli individuati, proviamo a ristimare il modello senza di essi.




Figura 3.5: Grafico di confronto diagnostica modello dati con e senza outliers

La rappresentazione grafica di diagnostica 3.5, che riporta in alto la diagnostica relativa al modello stimato sui dati completi e in basso quella relativa al modello stimato senza outliers, ci suggerisce come l'eliminazione di questi record riesca già a migliorare parzialmente la situazione. Tuttavia, le osservazioni, soprattutto nello Scale-Location e nel Residual vs Fitted, non sembrano del tutto distribuite in modo casuale.

Come già anticipato, si è proceduto a stimare il modello escludendo i record relativi all'Europa. Per procedere con questa operazione, sono stati filtrati i dati di training e di test in modo tale che non contenessero più i record relativi all'Europa. Inoltre, è stata rimossa la variabile *population* per evitare problemi di

multicollinearità determinati da essa. Questa scelta ha portato a un miglioramento iniziale per quanto riguarda la diagnostica del modello, sebbene non superiore a quello ottenuto eliminando i valori anomali (outliers). I restanti coefficienti del modello in questione sono comunque tutti molto significativi e la devianza risulta molto più grande dei gradi di libertà; il modello infatti, come quello calcolato in precedenza, risulta sovradisperso con statistica di Pearson rapportata ai gradi di libertà pari a 78.48248, quindi comunque meno del precedente. Per tutti i modelli appena stimati, per completezza, è stato eseguito un test per la sovradisersione che ha riportato, a sostegno della nostra tesi, tre p-value circa pari a 0.

3.2.2 STIMA DEL MODELLO NEGATIVE BINOMIAL

Dal momento che, come abbiamo ben visto, entrambi i modelli sopra calcolati risultano essere sovradispersi, andiamo a calcolare un modello Negative Binomial per vedere se questo, come vogliamo dimostrare, risolva i problemi di sovradisersione in caso di dati di conteggio. Esattamente come avveniva prima per la Poisson, il modello è stato applicato prima ai dati completi e poi ai dati senza i record riferiti al totale dell'Europa. Infatti, togliendo l'Europa dal dataset, molti problemi che si evidenziavano dai grafici di diagnostica scompaiono facilmente. Facciamo prima riferimento al modello risultante calcolato sui dati completi.

L'output di tale modello è il seguente:

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	7.202e-01	2.693e+00	0.267	0.7891
population	3.148e-07	2.998e-07	1.050	0.2936
cumulative_count_cases	-3.671e-09	2.736e-09	-1.341	0.1798
weekly_count_cases	1.443e-08	5.146e-08	0.280	0.7791
cumulative_count_deaths	6.880e-07	3.709e-07	1.855	0.0636 .
countryBelgium	-5.469e-01	7.965e-01	-0.687	0.4923
countryBulgaria	2.732e-01	6.501e-01	0.420	0.6743
countryCroatia	6.154e-01	1.537e+00	0.400	0.6889
countryCyprus	3.120e-01	2.423e+00	0.129	0.8975
countryCzechia	-7.384e-01	4.704e-01	-1.570	0.1165
countryDenmark	-6.535e-01	9.359e-01	-0.698	0.4850
countryEstonia	5.473e-01	2.295e+00	0.239	0.8115
countryEU/EEA (total)	-1.358e+02	1.330e+02	-1.021	0.3071

countryFinland	5.583e-01	1.033e+00	0.541	0.5889
countryFrance	-1.646e+01	1.765e+01	-0.933	0.3510
countryGermany	-2.117e+01	2.226e+01	-0.951	0.3416
countryGreece	-2.097e-01	4.540e-01	-0.462	0.6441
countryHungary	-3.384e-01	2.337e-01	-1.448	0.1477
countryIceland	-1.562e+00	2.583e+00	-0.605	0.5453
countryIreland	6.826e-01	1.179e+00	0.579	0.5626
countryItaly	-1.381e+01	1.500e+01	-0.921	0.3572
countryLatvia	5.984e-01	2.132e+00	0.281	0.7789
countryLiechtenstein	-3.223e+00	2.687e+00	-1.200	0.2303
countryLithuania	5.468e-01	1.853e+00	0.295	0.7680
countryLuxembourg	-1.969e-02	2.500e+00	-0.008	0.9937
countryMalta	-1.430e-01	2.538e+00	-0.056	0.9550
countryNetherlands	-2.268e+00	2.584e+00	-0.878	0.3801
countryNorway	-1.714e-01	1.070e+00	-0.160	0.8727
countryPoland	-7.887e+00	8.595e+00	-0.918	0.3588
countryPortugal	-2.869e-01	4.229e-01	-0.678	0.4976
countryRomania	-2.373e+00	3.017e+00	-0.787	0.4315
countrySlovakia	1.257e-01	1.067e+00	0.118	0.9062
countrySlovenia	7.330e-01	2.063e+00	0.355	0.7223
countrySpain	-1.031e+01	1.153e+01	-0.894	0.3712
countrySweden	-2.112e-01	4.522e-01	-0.467	0.6405
rate_14_day_cases	2.092e-04	1.368e-05	15.291	<2e-16 ***
rate_14_day_deaths	2.311e-02	2.686e-04	86.028	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.4671) family taken to be 1)

e riporta come non significativi quasi tutti i coefficienti, comprese la somma cumulata dei casi e delle morti, la popolazione e i casi settimanali.

La baseline della variabile categorica *country* è l'Austria, quindi tutte le dummies riferite alle altre Nazioni sono stimate come variazioni rispetto a questa. In altre parole, i coefficienti delle dummies rappresentano le differenze rispetto all'Austria.

La devianza di questo modello è pari a 5193.5, che, in relazione ai 4464 gradi

di libertà, risulta essere di poco superiore; pertanto il modello non sembra sovradisperso e, infatti, la statistica di Pearson rapportata ai gradi di libertà è addirittura inferiore a 1. Calcolando lo stesso modello con i dati senza i record relativi all'Europa, il risultato riguardo alla sovradisersione è lo stesso. La devianza, infatti, mostra sempre un netto miglioramento rispetto ai modelli Poisson ed è pari a 5051.9 su 4380 gradi di libertà. Per i coefficienti, la situazione è abbastanza differente: risultano non significativi solo alcuni di quelli relativi alle Nazioni e quello del conteggio settimanale dei casi.

In aggiunta, dopo aver verificato l'ipotesi con un apposito test, possiamo concludere che entrambi i modelli non presentano alcun outlier.

3.2.3 STIMA DI ULTERIORI MODELLI PER LA GESTIONE DELLA SOVRADISPERSIONE POISSON

Per completezza, calcoliamo rapidamente altri modelli che potrebbero adattarsi ancora meglio ai dati, quali il Quasi-Poisson, lo Zero Inflated Poisson, lo Zero Inflated Negative Binomial e l'Hurdle model.

Il modello Quasi-Poisson ha chiaramente la stessa quantità di sovradisersione della Poisson, ma sembra valutare più verosimilmente la significatività dei coefficienti, che, diversamente da come accadeva per la Poisson, risultano essere in parte meno significativi. La devianza residua è comunque pari a 550437, che, in relazione ai 4464 gradi di libertà, è comunque molto maggiore.

Il modello Zero Inflated Poisson come quello Zero Inflated Negative Binomial e l'Hurdle model sono stati calcolati sui dati completi di record dell'UE per evitare problemi legati alla multicollinearità, che avrebbero impedito la corretta stima degli stessi. Inoltre, per risolvere parzialmente questi problemi, che nei suddetti modelli erano ancora più accentuati, è stata eliminata la variabile *country*, che era la maggiore responsabile di tali criticità, e sono state standardizzate le altre variabili. Tutti e tre i modelli risultanti hanno quasi tutti i coefficienti significativi all'1%. In particolare il modello Zero Inflated Negative Binomial produce tutti coefficienti significativi per il modello di conteggio (Negative Binomial con link logaritmico) al netto di quello per *rate 14 day cases*, mentre per il modello Binomiale con link logit (quello che produce gli zeri delle ZINB) risultano significativi solo l'intercetta, il coefficiente delle popolazione e quello per *rate 14 day deaths*. Per il modello Zero Inflated Poisson, sono significativi tutti i coefficienti sia del modello Poisson che di quello Binomiale, tranne il secondo

dei coefficienti calcolati per *weekly count cases*. Per l'Hurdle model, sono invece significativi tutti i coefficienti (Attenzione: il modello produce dei NaN).

3.3 CONFRONTO MODELLI

Vediamo ora, graficamente e non, come questi modelli si adattano ai dati di test anche in relazione agli altri modelli. Considerando l'Akaike Information Criterion (AIC) e il Bayesian Information Criterion (BIC), riportati nella tabella 3.1, notiamo facilmente come il modello con AIC e BIC minore, che quindi dovrebbe adattarsi meglio ai dati, è il modello Negative Binomial. Ciò ci mostra, esattamente come volevasi dimostrare, come tale modello riesca a gestire molto bene la sovradisersione in caso di dati di conteggio. Si può anche osservare che i modelli stimati senza record relativi all'Europa risultano leggermente migliori rispetto a quelli con queste osservazioni.

	AIC	BIC
Poisson	574508.03	574745.27
Poisson no outliers	573755.20	573992.37
Poisson no UE	407732.83	407956.31
Negative Binomial	45198.04	45441.70
Negative Binomial no UE	42903.88	43133.74
Zero Inflated Poisson	1861993.88	1862070.83
Zero Inflated NegBin	48016.45	48099.81
Quasi-Poisson	NA	NA
Hurdle model	48466.23	48562.41

Tabella 3.1: Confronto dei diversi modelli attraverso AIC e BIC

Confrontiamo adesso la capacità di adattamento del modello ai dati di test. Da un'analisi del grafico 3.6, vediamo bene che in realtà quasi tutti i modelli stimati finora (tutti i modelli riportati nel grafico fanno riferimento ai dati di test del dataset completo) si adattano quasi alla stessa maniera ai dati e nessuno dei modelli riesce perfettamente a prevedere tutte le unità statistiche di test. Infatti, per nessuno di essi le osservazioni si trovano precisamente sulla bisettrice del quadrante. I modelli che, a occhio, sembrano performare meglio sono il modello Negative Binomial, quello Zero Inflated Negative Binomial e l'Hurdle model. Ci aspettiamo delle metriche sui dati di test abbastanza simili tra loro, dal momento che, a primo impatto, nessun modello si adatta particolarmente bene ai dati.




Figura 3.6: Grafico di confronto tra valori previsti e valori reali per ogni modello stimato

Per verificare quanto ipotizzato dall’analisi del grafico sopra riportato, calcoliamo delle metriche generali. La tabella 3.2 riporta per ogni modello il Mean Squared Error (MSE), il Root Mean Squared Error (RMSE), il Mean Absolute Error (MAE), e l’ R^2 , dove l’MSE, l’RMSE e il MAE, come si può facilmente evincere dal nome, sono misure di errore e l’ R^2 misura la bontà di adattamento del modello ai dati. Il modello migliore, quindi, dovrebbe avere le misure di errore minori e l’ R^2 maggiore.

	MSE	RMSE	MAE	R^2
Negative Binomial	4399.144	66.326	34.771	0.673
Poisson	14590.485	120.791	64.159	0.539
Quasi-Poisson	14590.485	120.791	64.159	0.539
Zero Inflated Negative Binomial	4517.519	67.212	34.413	0.674
Zero Inflated Poisson	15140.212	123.046	65.347	0.541
Hurdle	4870.042	69.786	4870.042	0.810

Tabella 3.2: Confronto dei diversi modelli attraverso alcune metriche

In generale, osservando la tabella, possiamo dire che tutti i modelli non si adattano così bene ai dati. Infatti, gli R^2 , al netto di quello dell’Hurdle model, sono tutti abbastanza bassi, e le misure di errore non risultano prossime allo zero. Il modello che sembra performare meglio è lo Zero Inflated Negative Binomial con misure di errore minori di tutti gli altri modelli e R^2 che è il secondo migliore. Si potrebbe preferire l’Hurdle model perché, nonostante riporti comunque valori

dell'MSE, RMSE e soprattutto del MAE abbastanza più elevati di quelli calcolati per il modello ZINB e per il Negative Binomial, riesce a spiegare l'81% della variabilità dei dati (R^2 prossimo a 1).

Per concludere, possiamo dire che, nel caso di questi dati relativi al COVID-19, il modello Negative Binomial riesce ad adattarsi molto bene ai dati di conteggio sovradispersi, anche con buone capacità di generalizzazione. Tutti gli errori, infatti, sono leggermente più alti di quelle del ZINB, mentre l' R^2 è di pochissimo inferiore e comunque riporta un AIC e un BIC minori di tutti gli altri modelli. In conclusione, come evidenziato dalle metriche calcolate sul test, sarebbe forse più opportuno preferire un modello Zero Inflated Negative Binomial o un Hurdle model. Quest'ultimi, infatti, sembrano più adatti a gestire l'eccessiva quantità di zeri nei dati, dovuti in particolare alle settimane iniziali della pandemia, durante le quali tutte le Nazioni hanno riportato un conteggio pari a zero per le morti.

Capitolo 4

CONCLUSIONE

La tesi è stata sviluppata per verificare l'utilità della Negative Binomial regression attraverso uno studio teorico e applicativo.

Ripercorrendo tutto ciò che è stato trattato, si può affermare che la Negative Binomial regression è un modello che si adatta bene a dati di conteggio in caso di sovradisersione, soprattutto quando la causa di tale sovradisersione non è nota. Chiaramente non è l'unica soluzione alla sovradisersione della Poisson e ci sono numerosi modelli più adatti a trattare casi specifici, come lo Zero Inflated Poisson/Zero Inflated Negative Binomial.

La sovradisersione è un fenomeno frequente nei casi reali di dati di conteggio e soprattutto nei modelli Poisson, che assumono che la varianza sia uguale alla media, cioè che ci sia equidispersione e, pertanto, che, all'aumentare della media, aumenti la variabilità. La violazione delle assunzioni alla base della Poisson risulta in sovradisersione che porta a sottostimare le deviazioni standard e sovrastimare la significatività dei coefficienti, portando a una scarsa interpretabilità dei risultati.

Il modello Negative Binomial permette, almeno nella sua versione più utilizzata, la parametrizzazione dell'eterogeneità della Poisson direttamente correlata alla sovradisersione. Tale forma di Negative Binomial, sviluppata come una mistura Poisson-Gamma, è chiamata NB2 e appartiene anche alla famiglia dei GLM portando con sé dunque anche tutti i vantaggi che ne derivano. La parametrizzazione dell'eterogeneità avviene tramite un parametro, indicato come α che, se posto pari a zero restituisce un semplice modello Poisson.

Innumerevoli i metodi di derivazione di questa distribuzione e altrettanto numerose le forme, tra le quali ricordiamo, oltre alla NB2, la NB1 e la NB-C. Quest'ultima è derivata direttamente dalla funzione di probabilità della Binomiale

e, dal momento che, al tendere di n a ∞ una distribuzione Binomiale tende a quella di Poisson, dalla Negative Binomial canonica si può facilmente derivare la NB2.

Tra i modelli che rientrano in quelli Negative Binomial abbiamo visto anche il modello geometrico, che si ha nel momento in cui α è pari a 1, e, la Negative Binomial bivariata che, nonostante le varie applicazioni che potrebbe avere, non è ancora stata approfondita a dovere.

A riprova dell'utilità del modello proposto in questa tesi, nella parte applicativa, sui dati COVID-19, abbiamo visto come effettivamente il modello Negative Binomial si adatti bene a casi di sovradisersione in dati di conteggio, dei quali erano un esempio i dati a nostra disposizione. Il modello si è dimostrato, infatti, utile per la gestione della sovradisersione anche se, in questo caso specifico, avremmo dovuto forse preferire altri modelli più adatti a trattare la vera causa della sovradisersione nei dati relativi alle morti settimanali dovute al COVID-19.

Appendice A

CODICE R

```
# importo i dati
library(tidyverse)
setwd("C:\\Users\\giudi\\OneDrive\\Desktop\\uni\\tesi")
dati <- read.csv("covid data.csv")

dati <- select(dati, - c(note, source, country_code, continent))

# nuovo dataset per analisi successive
dati2 <- dati %>%
  group_by(year_week, country) %>%
  pivot_wider(names_from = indicator, values_from = c(weekly_count,
    rate_14_day, cumulative_count), names_sep = '_')
dati2 <- as.data.frame(dati2)

# ANALISI DEI MISSING
vis_dat(dati2) +
scale_fill_manual(values= c('blue', 'seagreen2', 'violet', 'darkorchid'))

# tolgo i missing
dati2 <- dati2[complete.cases(dati2),]

# ANALISI DELLE CORRELAZIONI
library(ggcorrplot)
ggcorrplot(cor(dati2[, -c(1,3)]), lab = TRUE,
  lab_size = 3, colors = c("gold1", "seagreen2", "blue2"),
```

```
ggtheme = theme_minimal())

# GRAFICO PER L'ANALISI DELL'ANDAMENTO DELLA VARIABILE
d1 <- ggplot(dati2, aes(x = weekly_count_deaths)) +
  geom_histogram(aes(y = ..density..), binwidth = 10,
    fill = "blue2", alpha = 0.7, color = 'white') +
  geom_density(aes(y = ..density..), color = "seagreen2",
    fill = "seagreen2", alpha = 0.2, size = 1) +
  labs(title = "Distribuzione weekly count deaths dati completi",
    x = "Weekly Count Deaths",
    y = "Density") +
  scale_x_continuous(limits = c(0, 600)) +
  theme_bw()

dati2$country <- factor(dati2$country)
levels(dati2$country)

summary(dati2)

data_no_eu <- dati2[dati2$country != "EU/EEA (total)", ]

# test per vedere se la variabile si distribuisca come una Poisson
tab <- xtabs(~ weekly_count_deaths, data_no_eu)
ks.test(tab, 'ppois', mean(data_no_eu$weekly_count_deaths))

d2 <- ggplot(dati_no_eu, aes(x = weekly_count_deaths)) +
  geom_histogram(aes(y = ..density..), binwidth = 10, fill = "blue2",
    alpha = 0.7, color = 'white') +
  geom_density(aes(y = ..density..), color = "seagreen2",
    fill = "seagreen2", alpha = 0.2, size = 1) +
  labs(title = "Distribuzione weekly count deaths dati no eu",
    x = "Weekly Count Deaths",
    y = "Density") +
  scale_x_continuous(limits = c(0, 600)) +
  theme_bw()
```



```

library(gridExtra)
grid.arrange(d1, d2)

# BOXPLOT DELLE VARIABILI NORMALIZZATE
min_max_normalize <- function(x) {
  return((x - min(x)) / (max(x) - min(x)))
}

dati2_normalized <- as.data.frame(lapply(dati2[, -c(1, 3, 10, 11)],
                                         min_max_normalize))
dati2_long <- reshape2::melt(dati2_normalized)

ggplot(dati2_long, aes(x = variable, y = value, fill = variable)) +
  geom_boxplot(show.legend = F, color = 'black', linewidth = 0.2,
              outlier.alpha = 0.5) +
  scale_fill_manual(values = c("seagreen2", "blue", "cyan", "violet",
                                "blue2", "gold1", "darkorchid")) +
  theme_bw() +
  theme(axis.text.x = element_text(angle = 15, hjust = 1)) +
  labs(title = "Boxplot delle variabili normalizzate", x = "",
       y = "Valore Normalizzato")

#-----
# M O D E L L I
#-----

# DIVISIONE TRAINING E TEST IN BASE AL TEMPO year week
dati2$year <- as.numeric(sub("-.*", "", dati2$year_week))
dati2$week <- as.numeric(sub(".*-", "", dati2$year_week))

dati2 <- dati2 %>%
  arrange(year, week)

split_index <- floor(0.8 * nrow(dati2))

```

```
train_data <- dati2[1:split_index, ]
test_data <- dati2[(split_index + 1):nrow(dati2), ]

# POISSON
mod_poisson <- glm(weekly_count_deaths ~ population +
                  cumulative_count_cases + weekly_count_cases +
                  cumulative_count_deaths + country +
                  rate_14_day_cases + rate_14_day_deaths,
                  train_data, family = 'poisson')
summary(mod_poisson)

par(mfrow = c(2,2))
plot(mod_poisson)
par(mfrow = c(1,1))

sum(residuals(mod_poisson, type = 'pearson')^2)/mod_poisson$df.residual

library(car)
outlier_test <- outlierTest(mod_poisson)

outlier_indices <- which(outlier_test$bonf.p < 0.05)
dati_no_outlier <- train_data[-outlier_indices, ]

mod_poisson_no_out <- glm(weekly_count_deaths ~ population +
                        cumulative_count_cases + weekly_count_cases +
                        cumulative_count_deaths + country +
                        rate_14_day_cases + rate_14_day_deaths,
                        dati_no_outlier, family = 'poisson')
summary(mod_poisson_no_out)

par(mfrow = c(2,2))
plot(mod_poisson_no_out)
par(mfrow = c(1,1))

sum(residuals(mod_poisson_no_out, type = 'pearson')^2)/
```

```
mod_poisson_no_out$df.residual
```

```
# NEGATIVE BINOMIAL
```

```
library(MASS)
```

```
mod_nb <- glm.nb(weekly_count_deaths ~ population +  
                  cumulative_count_cases + weekly_count_cases +  
                  cumulative_count_deaths + country +  
                  rate_14_day_cases + rate_14_day_deaths, train_data)
```

```
summary(mod_nb)
```

```
sum(residuals(mod_nb, type = 'pearson')^2)/mod_nb$df.residual
```

```
par(mfrow = c(2,2))
```

```
plot(mod_nb)
```

```
par(mfrow = c(1,1))
```

```
outlierTest(mod_nb)
```

```
# QUASIPOISSON
```

```
mod_qp <- glm(weekly_count_deaths ~ population +  
              cumulative_count_cases + weekly_count_cases +  
              cumulative_count_deaths + country + rate_14_day_cases +  
              rate_14_day_deaths, train_data, family = 'quasipoisson')
```

```
summary(mod_qp)
```

```
par(mfrow = c(2,2))
```

```
plot(mod_qp)
```

```
par(mfrow = c(1,1))
```

```
# FILTRIAMO IL TRAINING E IL TEST IN MODO TALE CHE
```

```
# NON CONTENGANO I RECORD RELATIVI ALL'EUROPA
```

```
train_data2 <- filter(train_data, country!= 'EU/EEA (total)')
train_data2$country <- droplevels(train_data2$country)
table(train_data2$country)

test_data2 <- filter(test_data, country!= 'EU/EEA (total)')

# POISSON 2
mod_poi2 <- glm(weekly_count_deaths ~
                cumulative_count_cases + weekly_count_cases +
                cumulative_count_deaths + country +
                rate_14_day_cases + rate_14_day_deaths,
                data = train_data2, family = poisson)
summary(mod_poi2)

par(mfrow = c(2,2))
plot(mod_poi2)
par(mfrow = c(1,1))

sum(residuals(mod_poi2, type = 'pearson')^2)/mod_poi2$df.residual

library(AER)
dispersiontest(mod_poisson)
dispersiontest(mod_poi2)

# GRAFICI DI DIAGNOSTICA POISSON CON E SENZA OUTLIERS A CONFRONTO
library(broom)

model_data <- augment(mod_poisson)

# 1. Residuals vs Fitted
p1 <- ggplot(model_data, aes(.fitted, .resid)) +
  geom_point(alpha = 0.5) +
  geom_smooth(se = F, color = "seagreen2") +
  labs(title = "Residuals vs Fitted",
       x = "Fitted values",
```

```
    y = "Residuals") +
  theme_bw()

# 2. Normal Q-Q
p2 <- ggplot(model_data, aes(sample = .std.resid)) +
  stat_qq(alpha = 0.5) +
  stat_qq_line(linewidth = 1, color = "gold1") +
  labs(title = "Normal Q-Q",
        x = "Theoretical Quantiles",
        y = "Standardized Residuals") +
  theme_bw()

# 3. Scale-Location (Spread-Location)
p3 <- ggplot(model_data, aes(.fitted, sqrt(abs(.std.resid)))) +
  geom_point(alpha = 0.5) +
  geom_smooth( se = F, color = "blue2") +
  labs(title = "Scale-Location",
        x = "Fitted values",
        y = expression(sqrt(abs("Standardized Residuals")))) +
  theme_bw()

# 4. Residuals vs Leverage
p4 <- ggplot(model_data, aes(.hat, .std.resid)) +
  geom_point(alpha = 0.5) +
  geom_smooth( se = F, color = "violet") +
  labs(title = "Res. vs Leverage",
        x = "Leverage",
        y = "Standardized Residuals") +
  theme_bw()

grid.arrange(p1, p2, p3, p4)

model2_data <- augment(mod_poisson_no_out)

# 1. Residuals vs Fitted
p1_2 <- ggplot(model2_data, aes(.fitted, .resid)) +
```

```
geom_point(alpha = 0.5) +
geom_smooth(se = F, color = "seagreen2") +
labs(title = "Residuals vs Fitted",
      x = "Fitted values",
      y = "Residuals") +
theme_bw()

# 2. Normal Q-Q
p2_2 <- ggplot(model2_data, aes(sample = .std.resid)) +
  stat_qq(alpha = 0.5) +
  stat_qq_line(linewidth = 1, color = "gold1") +
  labs(title = "Normal Q-Q",
        x = "Theoretical Quantiles",
        y = "Standardized Residuals") +
  theme_bw()

# 3. Scale-Location (Spread-Location)
p3_2 <- ggplot(model2_data, aes(.fitted, sqrt(abs(.std.resid)))) +
  geom_point(alpha = 0.5) +
  geom_smooth(se = F, color = "blue2") +
  labs(title = "Scale-Location",
        x = "Fitted values",
        y = expression(sqrt(abs("Standardized Residuals")))) +
  theme_bw()

# 4. Residuals vs Leverage
p4_2 <- ggplot(model2_data, aes(.hat, .std.resid)) +
  geom_point(alpha = 0.5) +
  geom_smooth(se = F, color = "violet") +
  labs(title = "Res. vs Leverage",
        x = "Leverage",
        y = "Standardized Residuals") +
  theme_bw()

grid.arrange(p1_2, p2_2, p3_2, p4_2, nrow = 2)
```

```
grid.arrange(p1, p2, p3, p4, p1_2, p2_2, p3_2, p4_2, nrow = 2)
```

```
# NEGATIVE BINOMIAL 2
```

```
mod_nb2 <- glm.nb(weekly_count_deaths ~  
                  cumulative_count_cases +  
                  weekly_count_cases + cumulative_count_deaths +  
                  country + rate_14_day_cases +  
                  rate_14_day_deaths, train_data2)
```

```
summary(mod_nb2)
```

```
sum(residuals(mod_nb2, type = 'pearson')^2)/mod_nb2$df.residual
```

```
par(mfrow = c(2,2))
```

```
plot(mod_nb2)
```

```
par(mfrow = c(1,1))
```

```
outlierTest(mod_nb2)
```

```
# QUASIPOISSON 2
```

```
mod_qp2 <- glm(weekly_count_deaths ~  
               cumulative_count_cases + weekly_count_cases +  
               cumulative_count_deaths + country +  
               rate_14_day_cases + rate_14_day_deaths,  
               train_data2, family = 'quasipoisson')
```

```
summary(mod_qp2)
```

```
sum(residuals(mod_qp2, type = 'pearson')^2)/mod_qp2$df.residual
```

```
par(mfrow = c(2,2))
```

```
plot(mod_qp2)
```

```
par(mfrow = c(1,1))
```

```
# ZINB
```

```
library(pscl)
```

```
mod_zinb <- zeroinfl(weekly_count_deaths ~ population +  
                    cumulative_count_cases + weekly_count_cases +  
                    cumulative_count_deaths + country +  
                    rate_14_day_cases + rate_14_day_deaths,  
                    data = train_data, dist = "negbin")  
  
summary(mod_zinb)
```

```
# ZIP
```

```
mod_zip <- zeroinfl(weekly_count_deaths ~ population +  
                   cumulative_count_cases + weekly_count_cases +  
                   cumulative_count_deaths + country +  
                   rate_14_day_cases + rate_14_day_deaths,  
                   data = train_data, dist = "pois")  
  
summary(mod_zip)
```

```
# HURDLE
```

```
mod_hurdle <- hurdle(weekly_count_deaths ~ population +  
                     cumulative_count_cases + weekly_count_cases +  
                     cumulative_count_deaths + country +  
                     rate_14_day_cases + rate_14_day_deaths,  
                     data = train_data, dist = "negbin")  
  
summary(mod_hurdle)
```

```
# Standardizzo le variabili
```

```
train_data3 <- train_data
```

```
train_data3$weekly_count_cases <- scale(train_data3$weekly_count_cases)
```

```
train_data3$cumulative_count_deaths <-
```

```
scale(train_data3$cumulative_count_deaths)
```

```
train_data3$rate_14_day_cases <- scale(train_data3$rate_14_day_cases)
```

```
train_data3$rate_14_day_deaths <- scale(train_data3$rate_14_day_deaths)
```

```
train_data3$population <- scale(train_data3$population)
```



```

colnames(tab_confronto) <- c('AIC', 'BIC')
rownames(tab_confronto) <- c('Poisson', 'Poisson no outliers',
                             'Poisson no UE', 'Negative Binomial',
                             'Negative Binomial no UE',
                             'Zero Inflated Poisson',
                             'Zero Inflated NegBin',
                             'Quasi-Poisson', 'Hurdle model')

tab_confronto

# GRAFICO DI CONFRONTO

predicted <- predict(mod_nb, newdata = test_data, type = "response")
uno <- ggplot(test_data, aes(x = weekly_count_deaths, y = predicted)) +
  geom_point(alpha = 0.5) +
  geom_abline(slope = 1, intercept = 0, color = "gold1", linewidth = 1,
             linetype = 'dashed') +
  labs(title = "Negative Binomial",
       x = "Valori reali (test data)",
       y = "Valori previsti") +
  scale_y_continuous(limits = c(0,1500))+
  scale_x_continuous(limits = c(0,1500))+
  theme_bw()

predicted_poi <- predict(mod_poisson, newdata = test_data,
                        type = "response")
due <- ggplot(test_data, aes(x = weekly_count_deaths,
                             y = predicted_poi)) +
  geom_point(alpha = 0.5) +
  geom_abline(slope = 1, intercept = 0, color = "blue2",
             linewidth = 1, linetype = "dashed") +
  labs(title = "Poisson",
       x = "Valori reali (test data)",
       y = "Valori previsti") +
  scale_y_continuous(limits = c(0,1500))+

```

```
scale_x_continuous(limits = c(0,1500))+  
theme_bw()
```

```
predicted_qp <- predict(mod_qp, newdata = test_data,  
                        type = "response")  
tre <- ggplot(test_data, aes(x = weekly_count_deaths,  
                             y = predicted_qp)) +  
  geom_point(alpha = 0.5) +  
  geom_abline(slope = 1, intercept = 0, color = "seagreen2",  
              linewidth = 1, linetype = "dashed") +  
  labs(title = "Quasi-Poisson",  
        x = "Valori reali (test data)",  
        y = "Valori previsti") +  
  scale_y_continuous(limits = c(0,1500))+  
  scale_x_continuous(limits = c(0,1500))+  
  theme_bw()
```

```
predicted_zinb <- predict(mod_zinb, newdata = test_data,  
                          type = "response")  
quattro <- ggplot(test_data, aes(x = weekly_count_deaths,  
                                  y = predicted_zinb)) +  
  geom_point(alpha = 0.5) +  
  geom_abline(slope = 1, intercept = 0, color = "violet",  
              linewidth = 1, linetype = "dashed") +  
  labs(title = "ZINB",  
        x = "Valori reali (test data)",  
        y = "Valori previsti") +  
  scale_y_continuous(limits = c(0,1500))+  
  scale_x_continuous(limits = c(0,1500))+  
  theme_bw()
```

```
predicted_zip <- predict(mod_zip, newdata = test_data,
```

```

      type = "response")
cinque <- ggplot(test_data, aes(x = weekly_count_deaths,
  y = predicted_zip)) +
  geom_point(alpha = 0.5) +
  geom_abline(slope = 1, intercept = 0, color = "darkcyan",
    linewidth = 1, linetype = "dashed") +
  labs(title = "ZIP",
    x = "Valori reali (test data)",
    y = "Valori previsti") +
  scale_y_continuous(limits = c(0,1500))+
  scale_x_continuous(limits = c(0,1500))+
  theme_bw()

predicted_hurdle <- predict(mod_hurdle, newdata = test_data,
  type = "response")
sei <- ggplot(test_data, aes(x = weekly_count_deaths,
  y = predicted_hurdle)) +
  geom_point(alpha = 0.5) +
  geom_abline(slope = 1, intercept = 0, color = "darkorchid",
    linewidth = 1, linetype = "dashed") +
  labs(title = "Hurdle",
    x = "Valori reali (test data)",
    y = "Valori previsti") +
  scale_y_continuous(limits = c(0,1500))+
  scale_x_continuous(limits = c(0,1500))+
  theme_bw()

grid.arrange(uno, due, tre, quattro, cinque, sei, ncol = 3)

# CALCOLO DELLE METRICHE DI CONFRONTO TRA I MODELLI
library(Metrics)

mse_poisson <- mse(test_data$weekly_count_deaths, predicted_poi)
mse_nb      <- mse(test_data$weekly_count_deaths, predicted)

```

```
mse_qp      <- mse(test_data$weekly_count_deaths, predicted_qp)
mse_zip     <- mse(test_data$weekly_count_deaths, predicted_zip)
mse_zinb    <- mse(test_data$weekly_count_deaths, predicted_zinb)
mse_hurdle  <- mse(test_data$weekly_count_deaths, predicted_hurdle)

rmse_poisson <- round(rmse(test_data$weekly_count_deaths,
                           predicted_poi),3)
rmse_nb      <- round(rmse(test_data$weekly_count_deaths,
                           predicted),3)
rmse_qp      <- round(rmse(test_data$weekly_count_deaths,
                           predicted_qp),3)
rmse_zip     <- round(rmse(test_data$weekly_count_deaths,
                           predicted_zip),3)
rmse_zinb    <- round(rmse(test_data$weekly_count_deaths,
                           predicted_zinb),3)
rmse_hurdle  <- round(rmse(test_data$weekly_count_deaths,
                           predicted_hurdle),3)

mae_poisson  <- mae(test_data$weekly_count_deaths, predicted_poi)
mae_nb       <- mae(test_data$weekly_count_deaths, predicted)
mae_qp       <- mae(test_data$weekly_count_deaths, predicted_qp)
mae_zip      <- mae(test_data$weekly_count_deaths, predicted_zip)
mae_zinb     <- mae(test_data$weekly_count_deaths, predicted_zinb)
mae_hurdle   <- mae(test_data$weekly_count_deaths, predicted_hurdle)

r2_poisson  <- round(cor(test_data$weekly_count_deaths,
                          predicted_poi)^2,3)
r2_nb       <- round(cor(test_data$weekly_count_deaths,
                          predicted)^2,3)
r2_qp       <- round(cor(test_data$weekly_count_deaths,
                          predicted_qp)^2,3)
r2_zip      <- round(cor(test_data$weekly_count_deaths,
                          predicted_zip)^2,3)
r2_zinb     <- round(cor(test_data$weekly_count_deaths,
                          predicted_zinb)^2,3)
r2_hurdle   <- round(cor(test_data$weekly_count_deaths,
```

```
predicted_hurdle),3)
```

```
tab_metriche <- cbind(c(mse_nb, mse_poisson, mse_qp, mse_zinb,
                        mse_zip, mse_hurdle),
                     c(rmse_nb, rmse_poisson, rmse_qp, rmse_zinb,
                        rmse_zip, rmse_hurdle),
                     c(round(mae_nb, 3), round(mae_poisson, 3),
                        round(mae_qp, 3), round(mae_zinb, 3),
                        round(mae_zip, 3), round(mae_hurdle, 3)),
                     c(r2_nb, r2_poisson, r2_qp, r2_zinb,
                        r2_zip, r2_hurdle))

colnames(tab_metriche) <- c('MSE', 'RMSE', 'MAE', expression(("R")^2))
rownames(tab_metriche) <- c('Negative Binomial', 'Poisson',
                            'Quasi-Poisson',
                            'Zero Inflated Negative Binomial',
                            'Zero Inflated Poisson', 'Hurdle')

tab_metriche
```

Bibliografia

- BOSWELL, M. (1970). Chance mechanisms generating the negative binomial distributions. *Random counts in models and structures* , 3–22.
- CAMERON, A. C. & TRIVEDI, P. K. (1986). Econometric models based on count data. comparisons and applications of some estimators and tests. *Journal of applied econometrics* **1**, 29–53.
- ECDC (2023). Covid-19 coronavirus data weekly. <https://data.europa.eu/data/datasets/covid-19-coronavirus-data-weekly-from-17-december-2020?locale=en>.
- FENG, C. X. (2021). A comparison of zero-inflated and hurdle models for modeling zero-inflated count data. *Journal of statistical distributions and applications* .
- HALL, D. B. (2000). Zero-inflated poisson and binomial regression with random effects: A case study. *Biometrics* .
- HILBE, J. M. (2011). *Negative binomial regression*. Cambridge University Press.
- HILBE, J. M. (2014). *Modeling count data*. Cambridge University Press.
- HINDE, J. & DEMÉTRIO, C. G. (1998). Overdispersion: models and estimation. *Computational statistics & data analysis* **27**, 151–170.
- KLEIN, J. P., MOESCHBERGER, M. L. et al. (2003). *Survival analysis: techniques for censored and truncated data*, vol. 1230. Springer.
- MARSHALL, A. W. & OLKIN, I. (1990). Bivariate distributions generated from pólya-eggenberger urn models. *Journal of multivariate analysis* **35**, 48–65.
- MONTMORT, P. D. (1708). *Essay on the Analysis of Games of Chance*.
- SALVAN, A., SARTORI, N., PACE, L., SALVAN, A., SARTORI, N. & PACE, L. (2020). *Modelli lineari generalizzati*. Springer.

TODHUNTER, I. (1865). *History of the Mathematical Theory of Probability from the Time of Pascal to that of Laplace.*

RINGRAZIAMENTI

